



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE ENGENHARIA DE PRODUÇÃO
CURSO ENGENHARIA DE PRODUÇÃO MECÂNICA

Pietro Francisco Testoni

Aprendizado por reforço aplicado ao problema dinâmico de corte de bobinas

Florianópolis

2025

Pietro Francisco Testoni

Aprendizado por reforço aplicado ao problema dinâmico de corte de bobinas

Trabalho de Conclusão de Curso submetido ao curso de Engenharia de Produção Mecânica do Centro Tecnológico da Universidade Federal de Santa Catarina como requisito parcial para a obtenção do título de Bacharel em Engenharia Mecânica

Orientador: Prof. Lynceo Falavigna Braghirolli

Florianópolis

2025

Testoni, Pietro Francisco

Aprendizado Por Reforço Aplicado Ao Problema Dinâmico
de Corte de Bobinas / Pietro Francisco Testoni ;
orientador, Lynceo Falavigna Braghirolli, 2025.

94 p.

Trabalho de Conclusão de Curso (graduação) -
Universidade Federal de Santa Catarina, Centro
Tecnológico, Graduação em Engenharia de Produção Mecânica,
Florianópolis, 2025.

Inclui referências.

1. Engenharia de Produção Mecânica. 2. Aprendizado por
Reforço. 3. Problema de Corte de Bobinas. I. Braghirolli,
Lynceo Falavigna. II. Universidade Federal de Santa
Catarina. Graduação em Engenharia de Produção Mecânica.
III. Título.

Pietro Francisco Testoni

Aprendizado Por Reforço Aplicado Ao Problema Dinâmico de Corte de Bobinas:
Comparação Entre Agentes PPO e Programação Linear Inteira

Este Trabalho de Conclusão de Curso foi julgado adequado para obtenção do título de
Engenheiro Mecânico e aprovado em sua forma final pelo Curso de Engenharia de
Produção

Local: Auditório João E. E. Castro – EPS/CTC, 10 de Dezembro de 2025.

Insira neste espaço
a assinatura

Coordenação do Curso

Banca examinadora

Insira neste espaço
a assinatura

Prof Lynceo Falavigna Braghirolli
Orientador

Insira neste espaço
a assinatura

Prof.Sérgio Fernando Mayerle
Instituição UFSC

Insira neste espaço
a assinatura

Profa. Analúcia Schiaffino Morales
Instituição UFSC
Florianópolis, 2025

RESUMO

Esta pesquisa investiga o Problema Dinâmico de Corte de Bobinas em linhas de corte longitudinal sob regime de produção para estoque e compara duas abordagens: um agente de Aprendizado por Reforço (algoritmo de Otimização Proximal de Política) e um modelo de Programação Linear Inteira estática resolvido dia a dia. O sistema é modelado como um Processo de Decisão de Markov em dias discretos: o estado reúne estoques por comprimento, demanda observada e recursos operacionais; a ação escolhe um padrão viável do catálogo e a intensidade de corte; a recompensa corresponde ao negativo do custo diário (retalho, estoque e perda de venda), respeitando a hierarquia operacional. Implementa-se um simulador e utiliza-se um catálogo comum de padrões para as duas abordagens. Os experimentos abrangem instâncias com cinco e vinte itens (SKUs) sob demanda estocástica sintetizada e sementes controladas, com horizonte de trezentos dias e custos por milímetro, assegurando comparabilidade. A análise evidencia efeitos intertemporais que tornam políticas pontuais da Programação Linear Inteira mais sensíveis à variabilidade conforme cresce a combinatoriedade, enquanto o agente de Aprendizado por Reforço, treinado em episódios, aprende estoques de segurança e decisões antecipatórias. No cenário de cinco itens os métodos apresentam resultados semelhantes; no de vinte itens o agente de Aprendizado por Reforço alcança menor custo acumulado e reduz perdas de venda mantendo níveis de estoque ajustados. Conclui-se que políticas aprendidas capturam de forma robusta o compromisso entre retalho e inventário, posicionando o Aprendizado por Reforço como alternativa prática e escalável de apoio ao Planejamento e Controle da Produção em ambientes voláteis.

Palavras-chave: Cutting Stock Problem; corte CTL; make-to-stock; Proximal Policy Optimization; Programação Linear Inteira; trim-loss.

ABSTRACT

This research investigates the Dynamic Cutting Stock Problem in longitudinal cutting lines under a make-to-stock production regime and compares two approaches: a Reinforcement Learning agent (using the Proximal Policy Optimization algorithm) and a static Integer Linear Programming model solved day by day. The system is modeled as a Markov Decision Process in discrete days: the state includes inventory by length, observed demand, and operational resources; the action selects a feasible cutting pattern from the catalog and the cutting intensity; the reward corresponds to the negative of the daily cost (trim loss, inventory, and lost sales), respecting the operational hierarchy. A simulator is implemented and a shared catalog of cutting patterns is used for both approaches. The experiments cover instances with five and twenty items (SKUs) under synthesized stochastic demand and controlled seeds, with a 300-day horizon and calibrated cost parameters per millimeter, ensuring comparability. The analysis reveals intertemporal effects that make the day-to-day policies of Integer Linear Programming more sensitive to variability as combinatorial complexity increases, while the Reinforcement Learning agent, trained in episodes, learns to build safety stocks and make anticipatory decisions. In the five-item scenario, both methods yield similar results; in the twenty-item scenario, the Reinforcement Learning agent achieves lower accumulated cost and reduced lost sales while maintaining adjusted inventory levels. It is concluded that the learned policies robustly capture the trade-off between trim loss and inventory, positioning Reinforcement Learning as a practical and scalable alternative to support Production Planning and Control in volatile environments.

Keywords: Cutting Stock Problem; CTL cutting; make-to-stock; Proximal Policy Optimization; Mixed-Integer Linear Programming; trim loss.

LISTA DE FIGURAS

Figura 1 – Recompensa por episódio.....	77
Figura 2 – Custo acumulado por PPO.....	78
Figura 3 – Custo acumulado médio.....	79
Figura 4 – Distribuição dos custos	79
Figura 5 – Custo total acumulado.....	80
Figura 6 – Estoque médio	81
Figura 7 – Evolução do estoque diário	82
Figura 8 – Retalho total	82
Figura 9 – Perda de venda	83

LISTA DE QUADROS

Quadro 1 - Parâmetros de implementação (código/configuração)	73
Quadro 2 – Resultados PLI	74
Quadro 3 – Resultados RL	76

LISTA DE ABREVIATURAS E SIGLAS

1D	Problema unidimensional (one-dimensional)
A2C	Advantage Actor-Critic
API	Approximate Policy Iteration
CRU	CRU Group (consultoria internacional de aço)
CSP	Cutting Stock Problem
CTL	Cut-to-length
DQN	Deep Q-Network
E5	Ambiente experimental com 5 SKUs
E20	Ambiente experimental com 20 SKUs
IBGE	Instituto Brasileiro de Geografia e Estatística
IEA	International Energy Agency
MDP	Markov Decision Process
MILP	Mixed-Integer Linear Programming
MTS	Make-to-stock
NP	Classe de complexidade NP
PCP	Planejamento e Controle da Produção
PLI	Programação Linear Inteira
PPO	Proximal Policy Optimization
RL	Reinforcement Learning
SKU	Stock Keeping Unit
SKUs	Stock Keeping Units
SPSS	Statistical Package for the Social Sciences
UFSC	Universidade Federal de Santa Catarina

SUMÁRIO

1	INTRODUÇÃO.....	16
1.1	PROBLEMA DE PESQUISA.....	17
1.2	OBJETIVOS.....	18
1.2.1	Objetivo geral	18
1.2.2	Objetivos específicos	19
1.3	JUSTIFICATIVA.....	19
1.3.1	Relevância teórica.....	19
1.3.2	Relevância prática.....	20
1.4	DELIMITAÇÃO.....	20
1.5	ESTRUTURA DO TRABALHO.....	21
2	REFERENCIAL TEÓRICO	23
2.1	FUNDAMENTOS DE APRENDIZADO POR REFORÇO	23
2.1.1	Definição e Histórico do RL	23
2.1.2	Processos de Decisão de Markov (MDP)	24
2.1.3	Componentes Essenciais do RL (Política, Recompensa, Função de Valor, Modelo).....	27
2.1.4	Classes de Algoritmos de RL.....	28
2.1.5	Vantagens e Limitações Gerais das Técnicas de RL.....	31
2.2	PROBLEMA DE CORTE DE BOBINAS – CSP.....	33
2.2.1	Definição do CSP	34
2.2.2	Métricas de Avaliação (Desperdício, Número de Padrões, Tempo Computacional)	37
2.3	APLICAÇÕES DE RL AO CSP	38
2.3.1	Desafios e Oportunidades na Integração RL–CSP	39
2.3.2	Comparação com Modelos Clássicos (Benchmarking e Resultados Reportados)	41
2.3.2.1	<i>Contribuições de Pitombeira-Neto e Murta (2022)</i>	<i>42</i>
2.3.2.2	<i>Contribuições de Su et al.</i>	<i>43</i>
2.4	FORMULAÇÕES CLÁSSICAS PARA O CSP	44
2.4.1	Modelo de corte como problema de particionamento	44
2.4.2	Modelo de Corte formulado como PLI estático em padrões pré-gerados	

3	METODOLOGIA	47
3.1	CLASSIFICAÇÃO DE PESQUISA	47
3.2	PROCEDIMENTO METODOLÓGICO	48
3.2.1	Etapa 1- Como foi feito: da revisão à implementação	48
3.2.2	Etapa 2 - O que foi feito: desenvolvimento e estruturação dos modelos	49
3.2.3	Etapa 3, Comparação entre os dois modelos.....	50
3.3	MODELO DETERMINÍSTICO (PLI)	52
3.4	FERRAMENTAS E PLATAFORMAS PARA IMPLEMENTAÇÃO	53
3.5	ENCAMINHAMENTO PARA A FORMULAÇÃO DO PROBLEMA	55
4	FORMULAÇÃO DO PROBLEMA DE CORTE DINÂMICO COM	
	APRENDIZADO POR REFORÇO	57
4.1	CARACTERIZAÇÃO DO PROBLEMA DE CORTE DE BOBINAS.....	57
4.1.1	Definição geral do CSP 1D e elementos geométricos	57
4.1.2	Catálogo de padrões.....	58
4.1.3	Fluxo diário de produção, atendimento e estados.....	59
4.1.4	Custos operacionais e hierarquia de penalidades.....	59
4.1.5	Ritmo de decisão intra-dia e efeito do limite de setups	60
4.1.6	Horizonte de 300 dias e intertemporalidade do objetivo	61
4.2	HIPÓTESES E PRESSUPOSTOS DE MODELAGEM	61
4.2.1	Hipóteses determinísticas e lineares	61
4.2.2	Hipóteses estocásticas e temporais	61
4.2.3	Notação essencial para a modelagem sequencial	62
4.2.4	Premissas de equivalência experimental	62
4.3	FORMULAÇÃO COMO PROCESSO DE DECISÃO DE MARKOV	62
4.3.1	Propriedade markoviana e granularidade temporal.....	63
4.3.2	Dinâmica de transição e fechamento do ciclo diário.....	64
4.3.3	Objetivo de controle ótimo e comparação com MILP.....	64
4.4	ESPAÇO DE ESTADOS	65
4.5	ESPAÇO DE AÇÕES.....	66
4.6	FUNÇÃO DE RECOMPENSA E CUSTOS	67
4.7	GERAÇÃO DE DEMANDA E ESTOCASTICIDADE	69
4.8	POLÍTICA DE APRENDIZADO E ESTRUTURA COMPUTACIONAL.....	70
4.9	PARÂMETROS NUMÉRICOS ADOTADOS NO CÓDIGO	71

4.9.1	Custos e hierarquia de penalidades.....	71
4.9.2	Geometria da chapa e catálogos de padrões	71
4.9.3	Capacidade operacional, blocos intra-dia e espaço de ação.....	71
4.9.4	Geração de demanda e teto operacional diário.....	72
4.9.5	Hiperparâmetros do agente de política proximal	72
4.10	AMBIENTE DE APRENDIZADO	72
5	RESULTADOS	74
5.1	RESULTADOS DO MODELO PLI.....	74
5.2	RESULTADOS DO MODELO DE APRENDIZADO POR REFORÇO.....	76
5.3	COMPARAÇÃO ENTRE PLI E RL.....	78
5.4	DISCUSSÃO DOS RESULTADOS	83
6	CONCLUSÃO	86
	REFERÊNCIAS	90

1 INTRODUÇÃO

A cadeia de suprimentos dos aços planos, produtos siderúrgicos laminados (a quente ou a frio) cuja espessura é muito menor que a largura e o comprimento, comercializados em bobinas ou chapas, inicia-se com bobinas-mãe de largura padronizada enroladas ainda na usina. Antes de chegarem aos usuários finais (montadoras, fabricantes de linha-branca, tubulações etc.), essas bobinas são cortadas transversalmente em comprimentos menores em linhas de CTL (*cut-to-length*). O conjunto de comprimentos obtido em cada passada define um padrão; selecionar um conjunto de padrões que atenda todos os itens pedidos com a menor sobra possível constitui o clássico Problema de Corte de Bobinas (*Cutting Stock Problem* – CSP) unidimensional (GILMORE; GOMORY, 1961).

Embora o CSP pareça um simples exercício de aritmética, sua natureza combinatória cresce rapidamente: duplicar a quantidade de comprimentos distintos pode multiplicar por milhares os padrões viáveis (DYCKHOFF; FINKELSTEIN, 1991). Em plantas siderúrgicas que operam sob o regime *make-to-stock* (produção para estoque – MTS), essa complexidade é agravada porque os cortes são planejados antes de a demanda real se materializar. O Planejamento e Controle da Produção (PCP) precisa, portanto, equilibrar dois objetivos conflitantes:

1. Minimizar o retalho (parte da bobina-mãe que não se converte em produto útil);
2. Evitar excesso de estoque, que ocupa área de pátio e imobiliza capital.

Em cenários com grande variedade de comprimentos e demanda volátil, decisões tomadas num dia reverberam nos dias seguintes: produzir peças demais hoje reduz o retalho imediato, mas pode inflar estoques e restringir padrões futuros; produzir menos exige cortes emergenciais, geralmente menos eficientes. Surge, então, a necessidade de métodos que lidem simultaneamente com o estado (estoques por comprimento), o espaço de ação exponencial (padrões) e a incerteza temporal inerente ao ambiente MTS.

Abordagens exatas de PLI (Programação Linear Inteira) resolvem instâncias estáticas com demanda conhecida (GILMORE; GOMORY, 1963). Contudo, esses modelos tornam-se computacionalmente onerosos em horizonte rolante

(replanejamento contínuo), pois cada novo período exige resolver um problema completo.

Nesse contexto, este trabalho parte da constatação de que o CSP dinâmico de uma linha de CTL em ambiente MTS representa um problema sequencial sob incerteza que ainda carece de soluções capazes de conciliar qualidade de corte, velocidade de cálculo e robustez frente a variações de demanda. A pesquisa, portanto, busca explorar novos métodos que respondam a essa lacuna sem sacrificar a viabilidade operacional da usina.

1.1 PROBLEMA DE PESQUISA

O corte transversal de bobinas-mãe é planejado diariamente em horizonte rolante: a cada ciclo, o PCP deve decidir quais padrões de comprimento executar, levando em conta o saldo de estoque e previsões de demanda ainda incertas (POLDI; ARENALES, 2010). A dificuldade central reside em equilibrar, de forma integrada ao longo do tempo, a eficiência do corte, medida pela fração de material efetivamente aproveitado, e a disponibilidade de segmentos prontos para atender aos pedidos futuros. Essa decisão, aparentemente simples, transforma-se em um problema combinatório de grande escala quando se consideram dezenas de comprimentos distintos e variações abruptas de carteira.

A primeira barreira é a variabilidade da demanda. Listas de comprimentos são constantemente atualizadas por motivos cambiais, promoções de clientes ou sazonalidade, tornando obsoletos os planos calculados com base em dados congelados. Métodos clássicos que tratam cada período como uma instância independente não capturam esse dinamismo e, conseqüentemente, levam a replanejamentos frequentes que elevam custos de estoque e reduzem a eficiência global (POLDI; ARENALES, 2010; SILVA; MORABITO, 2020).

A segunda barreira é a interdependência temporal dos estoques. Produzir além da necessidade imediata diminui o desperdício do ciclo corrente, mas sobrecarrega o pátio e limita combinações viáveis no período seguinte; produzir menos implica cortes emergenciais normalmente menos eficientes. Heurísticas sequenciais, apesar de rápidas, ignoram essa conexão entre períodos e, assim, desperdiçam oportunidades de nivelar estoques e perdas no horizonte analisado (MENEZES; OLIVEIRA; LINS, 2017).

A terceira barreira é a escalabilidade computacional. Modelos exatos multi-período, capazes de representar o elo entre períodos, crescem exponencialmente em número de variáveis conforme aumenta a diversidade de comprimentos ou o tamanho do horizonte. O tempo de solução rapidamente ultrapassa as janelas operacionais do PCP, inviabilizando o uso rotineiro dessas abordagens em ambiente industrial (CAMPOS; MORABITO; GIL, 2018).

Esses três obstáculos, variabilidade, interdependência e escalabilidade, convergem para decisões subótimas que se materializam em duas consequências recorrentes: perdas de material acima dos patamares aceitáveis e estoques de segmentos parcialmente cortados que excedem a capacidade física de armazenamento. Ambos os efeitos pressionam custos e comprometem metas de sustentabilidade.

Diante desse cenário, o problema de pesquisa pode ser formulado da seguinte forma: como conceber políticas de planejamento de corte que, operando em um horizonte rolante sob demanda estocástica, promovam ganhos de eficiência e mantenham os estoques em níveis operacionais, sem ultrapassar a janela de tempo disponível ao PCP? A presente investigação pretende responder a essa indagação mediante a comparação sistemática entre método tradicional e algoritmo de aprendizado por reforço aplicados a duas instâncias de diferente escala. A escolha do aprendizado por reforço decorre de uma demanda externa, proveniente de uma empresa do setor, que solicitou explicitamente a avaliação dessa abordagem para o problema de corte em ambiente dinâmico.

1.2 OBJETIVOS

1.2.1 Objetivo geral

Propor uma abordagem baseada em aprendizado por reforço (*Reinforcement Learning* – RL) para o Problema de Corte de Bobinas unidimensional em linhas CTL operando sob regime MTS, demonstrando eficiência global em comparação com modelos de PLI.

1.2.2 Objetivos específicos

1. Construir modelos-referência baseados em PLI, calibrados em duas instâncias de diferentes dimensões.
2. Projetar um agente de aprendizado por reforço capaz de selecionar padrões por bloco a partir de um catálogo viável em horizonte rolante sob demanda incerta.
3. Comparar a eficiência do agente de RL com o modelo-referência, medindo retalho, estoque e atendimento da demanda.

1.3 JUSTIFICATIVA

1.3.1 Relevância teórica

O Problema de Corte de Bobinas tem longa tradição em Pesquisa Operacional, mas os avanços mais citados tratam instâncias estáticas e ignoram custos de estoque (GILMORE; GOMORY, 1963). Tentativas recentes de incorporar incerteza via programação estocástica elevam drasticamente o tamanho do modelo, limitando-se a problemas-piloto. Em paralelo, algoritmos de RL provaram eficiência em sequenciamento de produção, alocação de veículos e controle de inventários (ZHANG; GUO, 2022; ZHOU et al., 2023), mas poucos estudos abordam corte industrial sob horizonte rolante. A revisão sistemática de CHUNG et al. (2020) cita apenas dois artigos sobre RL e CSP, ambos em escalas laboratoriais sem custos de armazenagem. Ainda não há evidência de políticas treinadas em ambientes de grande dimensão, dezenas de comprimentos ativos, variabilidade diária de demanda e múltiplas penalidades, capazes de competir com PLI na qualidade da solução e no tempo de cálculo. Ao modelar o CSP dinâmico como um Processo de Decisão de Markov e treinar agentes Actor-Critic (PPO) ajustados a estados de estoque, esta pesquisa preenche a lacuna apontada por LI et al. (2023) e SILVA; PESSÔA (2021), ampliando a fronteira de RL aplicado a problemas combinatórios com restrições operacionais.

1.3.2 Relevância prática

O setor de aços planos responde por cerca de 7 % do PIB industrial brasileiro e emprega diretamente 120 mil trabalhadores (IBGE, 2024). Em 2023, a produção mundial superou 940 milhões t, com o Brasil contribuindo com 2,3 % (World Steel Association, 2024). Desse volume interno, 21 milhões t foram laminados planos; aproximadamente 15 % saíram das laminações como bobinas-mãe de largura única (Instituto Aço Brasil, 2024). Linhas CTL de grande porte operam em regime rolante; portanto, pequenos ganhos percentuais de eficiência se convertem em economias financeiras e redução de emissões relevantes (CRU, 2024; IEA, 2023). Além do impacto financeiro, normas ESG e o mercado global de carbono pressionam usinas a comprovar reduções de resíduos.

A demanda por chapas planas cortadas para o setor automotivo e chapas galvanizadas é notoriamente cíclica: picos em promoções de montadoras podem elevar pedidos semanais em 30%, enquanto recuos cambiais geram cancelamentos súbitos (ABRACIA, 2024). Tais variações pressionam o PCP a reprogramar ordens em menos de 15 min, intervalo em que modelos de otimização exata tornam-se inviáveis em instâncias de porte industrial, obrigando a adoção de heurísticas que, embora mais ágeis, resultam em acréscimo de desperdício operacional (ABRACIA, 2024).

1.4 DELIMITAÇÃO

Esta pesquisa delimita-se ao planejamento do corte transversal de bobinas-mãe de largura única em linhas CTL, operando sob o regime MTS. O foco analítico recai sobre o nível tático de decisão, isto é, a determinação diária dos padrões de corte que equilibram o uso eficiente do material e a manutenção de estoques operacionais adequados.

O estudo considera um horizonte rolante diário, no qual as decisões de corte são reavaliadas continuamente à medida que novas previsões de demanda são incorporadas. As entradas do modelo são compostas por demandas estocásticas simuladas, catálogo fixo de padrões de corte e limites de capacidade e estoque representativos de uma operação industrial típica.

O escopo inclui:

- a seleção de padrões de corte que atendam integralmente às demandas diárias, respeitando as restrições de capacidade da bobina-mãe;
- a representação dos níveis de estoque de segmentos e bobinas como variáveis de estado relevantes para o processo decisório;
- a avaliação comparativa entre abordagens determinísticas e adaptativas, utilizando métricas de desempenho baseadas em eficiência de corte (retalho), estoque médio acumulado e nível de atendimento da demanda.

Não se incluem neste estudo:

- etapas anteriores ou posteriores ao processo de corte (como laminação, inspeção ou expedição);
- características físicas da linha de produção, como posicionamento de facas, tempo de setup ou calibração de máquinas;
- aspectos econômicos, financeiros ou ambientais que extrapolem o desempenho operacional;
- controle em tempo real ou decisões de nível estratégico (investimentos, expansão de capacidade ou logística de distribuição).

Assim, o trabalho restringe-se à dinâmica decisória do corte em horizonte rolante, sob incerteza de demanda e parâmetros fixos de capacidade, com o objetivo de analisar o comportamento e a eficiência das políticas de planejamento neste contexto operacional específico.

1.5 ESTRUTURA DO TRABALHO

O Capítulo 1 apresenta o contexto da cadeia de suprimentos dos aços planos e a relevância do problema de corte de bobinas em linhas CTL sob regime MTS. São expostos a motivação prática do estudo, o problema de pesquisa, os objetivos geral e específicos, a justificativa acadêmica e industrial, bem como a delimitação do escopo considerado.

O Capítulo 2 reúne o Referencial Teórico que fundamenta a pesquisa. São apresentados os conceitos de Processos de Decisão de Markov e de Aprendizado por Reforço, incluindo estados, ações, recompensas, funções de valor e políticas. Por fim, são revisados trabalhos correlatos que combinam otimização matemática, heurísticas e técnicas de aprendizado em problemas de corte e planejamento de produção, situando a contribuição deste estudo no contexto da literatura.

O Capítulo 3 descreve a metodologia adotada na condução da pesquisa. São caracterizados o tipo de pesquisa e a abordagem metodológica, detalhando-se o delineamento experimental utilizado para comparar o modelo de Programação Linear Inteira e o agente de Aprendizado por Reforço. Apresentam-se os procedimentos de geração de dados de demanda, a construção dos padrões de corte, a definição dos ambientes experimentais com diferentes números de SKUs e o fluxo de simulação diário. Além disso, são especificados os critérios de desempenho e as métricas utilizadas para avaliar e comparar as soluções obtidas.

O Capítulo 4 trata da Formulação do Problema de corte dinâmico com Aprendizado por Reforço. Nesse capítulo, são formalizadas as variáveis de decisão, as restrições e a função objetivo do modelo de Programação Linear Inteira, utilizado como base determinística. Em paralelo, é descrita a modelagem do problema como um Processo de Decisão de Markov, definindo-se o espaço de estados, o espaço de ações, a dinâmica de transição, a função de recompensa e o horizonte de decisão do agente de RL. Também são apresentados em detalhe os ambientes experimentais considerados, os parâmetros operacionais adotados e a forma como o ciclo diário de decisões é implementado nos dois paradigmas.

O Capítulo 5 apresenta e analisa os Resultados obtidos com a aplicação dos modelos propostos. Inicialmente, são discutidos os resultados do modelo de Programação Linear Inteira nos diferentes ambientes, com ênfase no aproveitamento geométrico, nas sobras de corte e nos perfis de estoque gerados. Em seguida, são apresentados os desempenhos do agente de Aprendizado por Reforço treinado com PPO, explorando sua política dinâmica em termos de custos acumulados, evolução temporal dos estoques, padrões de corte acionados e ocorrência de perda de venda. Na sequência, é feita uma comparação sistemática entre PLI e RL, destacando ganhos e limitações de cada abordagem em dos cenários com complexidade distintas, bem como os efeitos da incerteza de demanda no comportamento das políticas.

Por fim, o Capítulo 6 reúne as conclusões do trabalho. São sintetizados os principais achados do estudo em relação ao desempenho comparativo entre o modelo determinístico e o agente RL. O capítulo apresenta as contribuições acadêmicas e gerenciais da pesquisa, as limitações do estudo e sugestões para trabalhos futuros.

2 REFERENCIAL TEÓRICO

2.1 FUNDAMENTOS DE APRENDIZADO POR REFORÇO

O Aprendizado por Reforço consiste em um arcabouço para que agentes autônomos aprendam, por tentativa e erro, políticas que maximizem a soma futura de recompensas obtidas durante interações sequenciais com o ambiente (SUTTON; BARTO, 2018). Sua fundamentação teórica repousa nos Processos de Decisão de Markov, que definem a dinâmica estado–ação–recompensa e introduzem os conceitos de política, função de valor e retorno descontado como elementos centrais da modelagem (PUTERMAN, 1994). Em essência, esse paradigma de aprendizagem permite que o agente melhore seu comportamento de forma incremental, testando diferentes ações e recebendo recompensas como feedback, sem supervisão externa direta. Dessa forma, o próprio agente descobre políticas eficazes a partir da interação reiterada com o ambiente, ajustando suas decisões para maximizar as recompensas acumuladas.

Comparado a outros paradigmas de Aprendizado de Máquina, o RL diferencia-se por não exigir exemplos de treinamento com “respostas corretas” previamente conhecidas; em vez disso, o agente gera seus próprios dados ao experimentar ações e observar as consequências (SUTTON; BARTO, 2018). Isso o torna especialmente atrativo para problemas em que não se conhece de antemão a solução ótima, mas é possível simular ou vivenciar diferentes decisões (KAELBLING; LITTMAN; MOORE, 1996). Um exemplo clássico é treinar um robô para navegar em um labirinto: o robô recebe uma recompensa positiva ao alcançar a saída e penalidades ao colidir com obstáculos; gradualmente ele aprende, por meio de tentativa e erro, quais ações o aproximam do objetivo final. Esse aprendizado autodirigido, guiado apenas por sinais de recompensa escalar, permite ao RL enfrentar problemas complexos em que a programação manual de uma solução seria inviável (ARULKUMARAN et al., 2017).

2.1.1 Definição e Histórico do RL

O RL é um arcabouço computacional em que um agente aprende, por tentativa e erro, uma política (π) que maximiza o retorno esperado ao interagir com um ambiente

estocástico descrito por um Processo de Decisão de Markov. A cada passo de tempo t , o agente observa o estado s_t , executa a ação a_t , recebe a recompensa r_t e transita para o próximo estado s_{t+1} , formando a sequência (s_t, a_t, r_t, s_{t+1}) que fundamenta a atualização da política (SUTTON; BARTO, 2018). Essa formulação baseia-se nos princípios de programação dinâmica apresentados por Puterman (1994), evidenciando a ligação do RL com o controle ótimo.

Os primeiros algoritmos de controle por reforço surgiram nas décadas de 1950 e 1960, mas o campo se consolidou na década de 1990. O survey de Kaelbling, Littman e Moore (1996) sintetizou os métodos baseados em valor e em política e delineou desafios de pesquisa. Posteriormente, técnicas de aproximação de funções mitigaram a chamada “maldição da dimensionalidade”, permitindo aplicações em problemas com grandes espaços de estados (POWELL, 2011). Vale notar que a maldição da dimensionalidade refere-se ao crescimento exponencial do número de estados conforme aumentam as variáveis do problema, tornando métodos tabulares inviáveis (BELLMAN, 1957). A aproximação por funções, como redes neurais ou bases de funções, ameniza esse problema ao generalizar experiências para estados não visitados explicitamente (MNIH et al., 2015).

Já no século XXI, a integração de redes neurais profundas impulsionou o RL, culminando no Deep Q-Network (DQN), que alcançou desempenho humano em jogos Atari (MNIH et al., 2015) e inaugurou a era do deep reinforcement learning, ampliando o uso do RL em jogos, robótica e otimização industrial. Com esses avanços, o RL firmou-se como uma abordagem promissora para enfrentar problemas complexos em diversas áreas, incluindo a otimização de processos industriais (MOHAMMED et al., 2020). Essa evolução abre caminho para considerar técnicas de RL em desafios clássicos de Pesquisa Operacional, como será investigado neste trabalho no contexto do problema de corte de bobinas (VRABIE; LEWIS; WANG, 2013).

2.1.2 Processos de Decisão de Markov (MDP)

Um Processo de Decisão de Markov é o modelo matemático que estrutura a dinâmica de interação entre agente e ambiente em problemas de Aprendizado por Reforço (PUTERMAN, 1994).

Formalmente, define-se um MDP como a quintupla (S, A, P, R, γ) , em que S é o conjunto de estados possíveis, A é o conjunto de ações viáveis, $P(s' | s, a)$ descreve a probabilidade de transição do estado s ao estado s' após a execução da ação a , $R(s, a)$ é a recompensa imediata associada a essa transição e $\gamma \in [0, 1]$ é o fator de desconto aplicado às recompensas futuras (PUTERMAN, 1994).

A cada passo de tempo t , o agente observa o estado s_t , escolhe uma ação a_t de acordo com sua política e recebe uma recompensa imediata $r(s_t, a_t)$; em seguida, o ambiente evolui estocasticamente para um novo estado s_{t+1} segundo a distribuição $P(s_{t+1} | s_t, a_t)$. Essa formulação caracteriza um problema de programação dinâmica estocástica, no qual as decisões são tomadas sequencialmente sob incerteza. Vale ressaltar que a propriedade de Markov implica que, dado o estado atual s e a ação escolhida a , o próximo estado s' independe dos estados anteriores - toda a informação relevante do passado está encapsulada em s . (SUTTON; BARTO, 2018). Essa memória limitada simplifica a análise de processos sequenciais e é válida para uma ampla gama de problemas de decisão (PUTERMAN, 1994).

O objetivo do agente é maximizar o retorno esperado acumulado a longo prazo. Para formalizar esse conceito, define-se o retorno a partir de um instante t como $G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$, ou seja, a soma das recompensas futuras descontadas pelo fator γ . O uso de $\gamma < 1$ faz com que recompensas obtidas mais adiante no tempo tenham peso menor, refletindo uma preferência por ganhos imediatos (ou maior incerteza em recompensas muito futuras) e garantindo que a série de recompensas convirja (SUTTON; BARTO, 2018). Com base nisso, introduzem-se as funções de valor associadas a uma política π : a função valor de estado $V^\pi(s)$, que representa a expectativa do retorno a partir do estado s seguindo a política π , e a função valor de ação $Q^\pi(s, a)$, que fornece a expectativa do retorno ao escolher a ação a no estado s , e então seguir a política π daí em diante. Intuitivamente, $V^\pi(s)$ indica o quão bom é estar no estado s sob a política π , enquanto $Q^\pi(s, a)$ indica o quão vantajoso é executar a ação a no estado s sob essa política. Essas funções permitem avaliar decisões de forma indireta, sem precisar simular até o final de cada episódio para cada possível escolha.

A equação de Bellman decorre do princípio de otimalidade de Bellman, segundo o qual uma política ótima possui a propriedade de que, independentemente do estado inicial e da primeira decisão, as decisões subsequentes devem constituir

uma política ótima em relação ao estado resultante dessa decisão (BELLMAN, 1957). Com base nesse princípio, estabelece-se uma relação recursiva para as funções de valor, permitindo decompor o problema global em subproblemas menores e interdependentes (SUTTON; BARTO, 2018). Em palavras, ela afirma que o valor esperado de um estado s (sob uma política π) equivale à recompensa imediata esperada naquele estado mais o valor esperado descontado do próximo estado resultante, seguindo π . Matematicamente, para cada estado s tem-se:

$$V^\pi(s) = \sum_{a \in A} \pi(a | s) \left[R(s, a) + \gamma \sum_{s' \in S} P(s' | s, a) V^\pi(s') \right]. \quad (1)$$

Nessa expressão, $\pi(a | s)$ representa a probabilidade de selecionar a ação a no estado s segundo a política π ; $R(s, a)$ corresponde à recompensa imediata associada à execução da ação a no estado s ; $P(s' | s, a)$ denota a probabilidade de transição do estado s para o estado s' após a execução da ação a ; $\gamma \in [0, 1]$ é o fator de desconto aplicado às recompensas futuras; A representa o conjunto de ações viáveis e S o conjunto de estados possíveis. Assim, $V^\pi(s)$ corresponde ao valor esperado do retorno acumulado ao seguir a política π a partir do estado s .

Ao representar o corte de bobinas como um MDP, é possível capturar formalmente a dinâmica do problema por meio da definição explícita do vetor de estado, do conjunto de ações disponíveis, da função de recompensa e das probabilidades de transição entre estados. Nesse contexto, (i) o estado do sistema descreve, por exemplo, os níveis de estoque atuais de cada comprimento e a demanda restante a satisfazer em um dado momento; (ii) as ações disponíveis em cada decisão correspondem à escolha de um padrão específico de corte a ser aplicado em uma bobina naquele instante; e (iii) a recompensa imediata obtida reflete, por exemplo, uma penalização associada ao retalho gerado e ao eventual excesso de estoque produzido pela ação. Com essa modelagem, cada episódio do MDP corresponde a uma sequência de cortes ao longo de vários períodos, e a soma das recompensas reflete o desempenho acumulado (negativo dos custos) dessa sequência de decisões. Essa formulação traduz o CSP dinâmico para os termos padrão do Aprendizado por Reforço, preparando o terreno para a aplicação de métodos avançados no problema de corte de bobinas.

2.1.3 Componentes Essenciais do RL (Política, Recompensa, Função de Valor, Modelo)

Nesta subseção, descrevem-se os quatro componentes fundamentais do Aprendizado por Reforço. A política π define como o agente escolhe ações em cada estado, isto é, é a regra de decisão do agente. Ela pode ser determinística (sempre escolhe a mesma ação para um dado estado) ou estocástica (atribui probabilidades a cada ação em um estado) (SUTTON; BARTO, 2018). Durante o aprendizado, costuma-se empregar políticas estocásticas ou ϵ -gulosas para garantir que o agente explore ações alternativas ocasionalmente, em vez de ficar apenas na melhor ação conhecida, já que essa exploração é necessária para descobrir estratégias potencialmente melhores (SUTTON; BARTO, 2018; THRUN, 1992). Em outras palavras, existe um equilíbrio entre exploração (experimentar ações novas para adquirir conhecimento) e exploração (utilizar o que já se sabe que funciona), e a política define como esse equilíbrio se manifesta nas escolhas do agente.

O sinal de recompensa r_t fornece feedback imediato sobre a ação executada. Trata-se de um valor numérico (escalar) que indica quão boa ou ruim foi a consequência daquela ação no estado corrente (SUTTON; BARTO, 2018). Por exemplo, no contexto do CSP, podemos definir a recompensa de forma a penalizar o desperdício de material e penalizar também excessos de estoque: assim, ações que resultem em baixo retalho e em estoques controlados geram penalidades menores (recompensas mais altas), indicando ao agente que esse é um resultado desejável. O agente observa essa recompensa logo após executar a ação e utiliza essa informação para ajustar seu comportamento futuro.

A função de valor quantifica o retorno esperado a longo prazo. De forma específica, a função valor de estado $V(s)$ estima o retorno esperado futuro a partir do estado s , enquanto a função valor de ação $Q(s, a)$ estima o retorno esperado ao tomar a ação a no estado s . (SUTTON; BARTO, 2018) Em outras palavras, $V(s)$ indica quão promissor é estar em s (considerando as recompensas futuras que se obterão, em média, a partir dali) e $Q(s, a)$ indica quão vantajoso é escolher a ação a quando se está em s . Essas funções são centrais no RL porque permitem ao agente avaliar decisões sem precisar simular todo um episódio para cada escolha possível: $V(s)$ e $Q(s, a)$

servem como uma forma de “memória” ou predição de desempenho, orientando o agente a preferir estados e ações de maior valor esperado (SUTTON; BARTO, 2018).

Por fim, o modelo do ambiente, representado por $P(s' | s, a)$ e $R(s, a)$ descreve as probabilidades de transição e as recompensas associadas a cada interação (SUTTON; BARTO, 2018). O modelo, quando disponível, permite ao agente simular sequências de interações de maneira hipotética – ou seja, planejar mentalmente. Se o agente conhece o modelo, ele pode prever qual seria o próximo estado e recompensa para cada ação e, assim, usar métodos de planejamento (por exemplo, busca em árvore de decisões ou simulações via Monte Carlo) para melhorar sua política sem interação real. Por outro lado, muitos algoritmos de RL não utilizam modelo (model-free), aprendendo apenas a partir da experiência (amostras de transições observadas).

2.1.4 Classes de Algoritmos de RL

As classes de algoritmos de Aprendizado por Reforço se distinguem pela forma de otimização adotada para aprimorar a política do agente. Nos métodos baseados em valor, como o Q-Learning, o agente busca aproximar diretamente a função ação-valor ótima $Q(s, a)$ sem requerer um modelo do ambiente, atualizando iterativamente estimativas de $Q(s, a)$ até a convergência (SUTTON; BARTO, 2018). Por exemplo, no algoritmo Q-Learning – um dos métodos baseados em valor mais difundidos – a cada transição observada (s_t, a_t, r_t, s_{t+1}) , o valor estimado é atualizado de acordo com a fórmula:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a' \in A} Q(s_{t+1}, a') - Q(s_t, a_t) \right] \quad (2)$$

, onde α é a taxa de aprendizado (SUTTON; BARTO, 2018). Essa regra de atualização ajusta $Q(s_t, a_t)$ na direção do erro temporal – a diferença entre o valor atual e a estimativa atualizada com a recompensa imediata mais o valor futuro potencial. Em termos intuitivos, o algoritmo incrementa $Q(s_t, a_t)$ se a recompensa imediata + valor futuro observado foi maior do que o esperado, ou decrementa caso contrário. Métodos baseados em valor como esse têm a vantagem de não exigirem conhecimento prévio das dinâmicas do ambiente e, sob certas condições, podem garantir convergência

para Q e para a política ótima correspondente. Essas garantias de convergência são válidas sob hipóteses clássicas, como espaço de estados e ações finito, ambiente estacionário, exploração suficiente de todas as ações e escolha adequada da taxa de aprendizado, que deve satisfazer condições de decaimento ao longo do tempo. Nessas circunstâncias, o *Q-Learning* converge com probabilidade um para a função ação-valor ótima Q^* (SUTTON; BARTO, 2018). Cabe destacar que, embora o *Q-Learning* possua garantia teórica de convergência para a função ação-valor ótima Q^* , essa convergência não é imediata nem garantida durante o processo de aprendizado. Como a política ótima não é conhecida a priori, a exploração de ações alternativas é necessária para obter estimativas consistentes de $Q(s, a)$ e evitar a convergência prematura para soluções subótimas.

Por outro lado, métodos baseados em política, como o algoritmo REINFORCE (gradiente de política estocástico), ajustam diretamente os parâmetros de uma política estocástica por meio do gradiente da performance esperada (WILLIAMS, 1992; SUTTON; BARTO, 2018). Em vez de aprender uma função de valor e derivar a política a partir dela, esses métodos mantêm uma representação paramétrica $\pi_\theta(a|s)$ e modificam θ para maximizar o retorno esperado. Em essência, aumentam-se as probabilidades das ações que conduzem a altos retornos e reduzem-se as daquelas que geram retornos baixos. Por exemplo, o algoritmo REINFORCE ajusta os parâmetros θ na direção de $\nabla_\theta \ln \pi_\theta(a_t|s_t), G_t$, onde G_t é o retorno observado a partir da etapa t (WILLIAMS, 1992; SUTTON; BARTO, 2018). O termo $\nabla_\theta \ln \pi_\theta(a_t | s_t)$ representa o gradiente do logaritmo da política em relação aos seus parâmetros, indicando a direção na qual os parâmetros θ devem ser ajustados para aumentar a probabilidade de selecionar ações que produziram maiores retornos. Essa formulação permite estimar o gradiente da política a partir de amostras, sem exigir um modelo explícito do ambiente. Nessa formulação, θ representa o vetor de parâmetros da política estocástica $\pi_\theta(a | s)$, responsável por determinar como a política mapeia estados observados em probabilidades de seleção de ações. Isso significa que, se uma trajetória produz retorno acima do esperado, as ações tomadas nessa trajetória terão suas probabilidades elevadas (são “recompensadas”), enquanto trajetórias de baixo retorno resultam em redução de probabilidade para as ações selecionadas (são “punidas”). Métodos de gradiente de política têm a propriedade desejável de otimizar diretamente a política e podem lidar naturalmente com espaços de ação contínuos,

embora possam sofrer com variância alta nas estimativas de gradiente (WILLIAMS, 1992; SCHULMAN et al., 2015). Essa variância elevada é um dos principais desafios desses métodos, o que motiva técnicas para reduzi-la – como o uso de um “baseline” (por exemplo, subtrair $V(s)$ do retorno observado) – e abre caminho para métodos mais sofisticados, como os atores-críticos. Como o REINFORCE ajusta diretamente os parâmetros da política a partir do retorno observado, sem o uso explícito de uma função de valor intermediária, o método apresenta elevada variância nas estimativas de gradiente. Essa característica torna sua aplicação mais adequada a ambientes relativamente estáveis, nos quais a dinâmica do sistema não sofre variações significativas ao longo do aprendizado.

Abordagens híbridas, denominadas ator-crítico (*actor-critic*), combinam a estimativa de valores com a otimização direta da política (KONIDARIS; BARTO, 2009; SUTTON; BARTO, 2018). Nesses métodos, um componente ator (a política propriamente dita) propõe as ações com base na política atual, e um componente crítico avalia as ações realizadas calculando algum tipo de erro ou vantagem. Nesse contexto, o crítico avalia as ações executadas estimando uma função de valor, como $V(s)$ ou $Q(s, a)$, e fornece ao ator um sinal de feedback que indica se a ação tomada foi melhor ou pior do que o esperado. Esse feedback é frequentemente expresso por uma medida de vantagem, permitindo que o ator ajuste seus parâmetros θ de forma mais estável e informativa do que em métodos de gradiente de política puros. O crítico geralmente aprende uma função de valor usando métodos baseados em valor, enquanto o ator ajusta os parâmetros da política usando o feedback fornecido pelo crítico. Essa arquitetura reduz a variância dos gradientes de política e pode acelerar a convergência, pois o crítico fornece um sinal de aprendizado mais informativo ao ator (SUTTON; BARTO, 2018). Abordagens ator-crítico – incluindo variantes modernas como o PPO (*Proximal Policy Optimization*) – são amplamente empregadas em problemas de grande porte devido à sua eficiência computacional e estabilidade de treinamento comprovada (SCHULMAN et al., 2017). Algoritmos como PPO tornaram-se padrões na comunidade por permitirem passos de atualização maiores na política sem divergir, acelerando o aprendizado em comparação com métodos de política mais simples (SCHULMAN et al., 2017).

2.1.5 Vantagens e Limitações Gerais das Técnicas de RL

O Aprendizado por Reforço oferece diversas vantagens em comparação com métodos tradicionais de otimização e controle (VRABIE; LEWIS; WANG, 2013; MOHAMMED et al., 2020). Uma das principais é a capacidade de lidar com problemas sequenciais e estocásticos de alta dimensionalidade sem exigir modelagens exatas do ambiente. Isso significa que o RL pode aprender políticas eficazes mesmo quando o problema não pode ser descrito facilmente por equações ou quando há incerteza significativa nas transições ou recompensas. Além disso, o RL permite um aprendizado adaptativo em tempo real: à medida que o ambiente muda ou o agente encontra situações novas, ele pode ajustar gradualmente sua política, diferentemente de métodos estáticos que precisariam ser reotimizados do zero (SUTTON; BARTO, 2018; VRABIE; LEWIS; WANG, 2013). Por exemplo, algoritmos de RL já demonstraram sucesso em tarefas de controle de inventário e sequenciamento de produção sob incerteza, superando heurísticas tradicionais ao se adaptarem dinamicamente às condições variáveis (ZHANG; GUO, 2022; ZHOU et al., 2023). Essas características tornam o RL especialmente atrativo para problemas nos quais a dinâmica do sistema é complexa ou mal conhecida e para aqueles em que decisões devem ser tomadas continuamente com base em feedback recebido – casos em que técnicas clássicas de programação matemática se tornam difíceis de aplicar ou custosas em termos de tempo de processamento.

Por outro lado, as técnicas de RL apresentam algumas limitações importantes. A primeira delas é a alta sensibilidade a escolhas de hiperparâmetros. O desempenho de um agente de RL pode variar drasticamente dependendo de parâmetros como a taxa de aprendizado (α), o fator de desconto (γ), o método de exploração (por exemplo, o valor de ϵ em uma política ϵ -gulosa) e a arquitetura da função de aproximação (por exemplo, o número de neurônios em cada camada de uma rede neural) (HENDERSON et al., 2018; RAIHANI; MAHMOOD, 2021). Ajustar esses hiperparâmetros geralmente requer extensa experimentação e validação, e escolhas inadequadas podem impedir a convergência ou levar o agente a convergir para políticas de baixa qualidade (SUTTON; BARTO, 2018). Essa necessidade de ajuste fino adiciona uma camada de complexidade ao desenvolvimento de soluções em RL, que não aparece, por exemplo, em modelos de otimização linear onde técnicas padronizadas garantem a obtenção do ótimo.

Além disso, os algoritmos de RL costumam demandar uma grande quantidade de iterações com o ambiente para atingir um desempenho satisfatório. Em problemas onde cada interação (episódio) é custosa ou demorada de simular, essa característica se torna um gargalo (KAELBLING; LITTMAN; MOORE, 1996; LAKE et al., 2017). Mesmo em simulação, treinar um agente pode envolver milhões de passos de interação antes de estabilizar, o que implica alto custo computacional. Embora existam técnicas para melhorar a eficiência de amostragem – como *experience replay* (reaproveitar experiências passadas) ou aprendizado offline em bases de dados pré-coletados – a demanda por dados permanece elevada (SUTTON; BARTO, 2018). No contexto industrial, onde tempo computacional e dados podem ser limitados, essa necessidade pode dificultar a aplicação direta do RL.

Outra limitação relevante é a falta de explicabilidade dos agentes treinados (PUIJENBROEK et al., 2021; PIROLA; CERRI; MAGGIO, 2022). As políticas resultantes do RL, especialmente quando parametrizadas por redes neurais profundas, são essencialmente modelos de caixa-preta: não é trivial extrair regras claras que expliquem por que o agente tomou determinada decisão em certo estado. Diferentemente de um modelo de Programação Linear que permite algum grau de interpretação (como “nunca ultrapassar capacidade”), um agente de RL pode aprender estratégias complexas que são difíceis de interpretar. Essa ausência de transparência pode ser problemática em cenários onde se requer a validação ou justificativa das decisões – por exemplo, se o agente recomendar um padrão de corte contraintuitivo, gestores humanos podem hesitar em implementá-lo sem compreender os motivos. A literatura de RL vem explorando métodos de interpretação e visualização (por exemplo, análise da importância de estados ou ênfase de características), mas ainda é um campo em desenvolvimento e, de modo geral, RL carece da clareza de métodos de otimização tradicionais em termos de explicação da solução encontrada (PUIJENBROEK et al., 2021; PIROLA; CERRI; MAGGIO, 2022).

Nesses casos, a eficiência da política aprendida não é avaliada por garantias formais de otimalidade, mas por critérios empíricos de desempenho. Em particular, considera-se eficiente uma política que apresenta desempenho consistente e superior em métricas relevantes do problema, como custo médio, desperdício ou nível de serviço, quando comparada a métodos de referência em um conjunto representativo de instâncias. Assim, a validação da política em aprendizado por reforço baseia-se

em testes experimentais, análise estatística dos resultados e comparação com abordagens tradicionais, em vez de certificados formais de ótimo.

Por fim, há a questão das garantias de convergência e desempenho ótimo em problemas de grande escala. Diferentemente de algoritmos de otimização clássicos (como o simplex em programação linear ou branch-and-bound em programação inteira) que fornecem certificados de otimalidade ou limites de erro, os algoritmos de RL em domínios complexos não oferecem, em geral, garantias estritas de convergir para a política ótima global em tempo polinomial. Em espaços de estados contínuos ou extremamente amplos, o agente pode não explorar suficientemente todas as configurações relevantes ou pode ficar preso em ótimos locais. No caso do CSP dinâmico, que possui um espaço combinatorial elevado de configurações de estoque e padrões aplicáveis, Pitombeira-Neto et al. (2021) ressaltam que não é trivial garantir que um agente de RL encontre políticas realmente ótimas dentro de um tempo de treinamento razoável. Eles verificaram que foi necessário limitar o escopo do problema e usar funções de valor aproximadas (em vez de tabulares) para tornar o aprendizado factível – ainda assim, com um custo computacional considerável. Em suma, embora o RL apresente grande potencial, sua aplicação a cenários industriais de larga escala impõe desafios quanto à estabilidade, tempo de convergência e qualidade garantida da solução, requerendo muitas vezes combinações com heurísticas ou técnicas de aproximação para atingir desempenho satisfatório (MOHAMMED et al., 2020; ZHANG; YANG; BASAR, 2021).

2.2 PROBLEMA DE CORTE DE BOBINAS – CSP

O CSP é um desafio clássico de Pesquisa Operacional que surge sempre que se precisa dividir um material longo e contínuo, como uma bobina de aço, um rolo de tecido ou uma tira de plástico, em pedaços menores para atender a pedidos de comprimentos específicos (GILMORE; GOMORY, 1963; WÄSCHER; HAUSSNER; SCHUMANN, 2007). Na versão unidimensional, cada padrão de corte define uma combinação de comprimentos que cabe exatamente (ou quase) na bobina. O CSP consiste em determinar quais padrões de corte adotar e quantas bobinas usar em cada padrão, de modo a satisfazer toda a demanda e minimizar o total de sobra de material (retalho).

Em plantas siderúrgicas, o CSP refere-se às bobinas-mãe padronizadas, que são cortadas em comprimentos menores em linhas de cut-to-length (CTL). Nesses

ambientes, a grande variedade de comprimentos solicitados e a volatilidade da demanda tornam o problema ainda mais complexo (VARELA; MORABITO; RANGEL, 2018). O CSP é notoriamente difícil: duplicar a quantidade de tipos de comprimentos pode multiplicar exponencialmente o número de padrões viáveis a considerar. Trata-se de um problema NP-difícil (GAREY; JOHNSON, 1979), ou seja, o número de combinações de corte cresce tão rapidamente com o aumento dos tipos de itens que não se conhece um algoritmo eficiente de tempo polinomial que sempre encontre a solução ótima. O CSP unidimensional é intimamente relacionado ao conhecido problema de empacotamento de itens (Bin Packing), que também é NP-difícil. Essa explosão combinatória implica que métodos exatos resolvem apenas instâncias pequenas ou medianas dentro de um tempo viável, sendo que instâncias de porte industrial muitas vezes requerem aproximações (WÄSCHER; HAUSSNER; SCHUMANN, 2007; MARTELLO; VIGO, 2020).

A formulação matemática clássica do CSP unidimensional foi proposta por Gilmore & Gomory (1961; 1963) e expressa o problema como um modelo de Programação Linear Inteira (PLI). Em termos gerais, diversas heurísticas sequenciais também são utilizadas para obter soluções rápidas em cenários de alta demanda e replanejamento contínuo, embora tipicamente à custa de uma qualidade um pouco inferior em termos de aproveitamento de material (POLDI; ARENALES, 2010).

2.2.1 Definição do CSP

O CSP unidimensional considera um conjunto de m tipos de itens de comprimento fixo (digamos, $l_1, l_2, \dots, l_m$) e uma bobina-mãe de comprimento padronizado L . Para cada tipo de item i (com $i = 1, \dots, m$) há uma demanda d_i específica, representando quantos segmentos desse comprimento devem ser produzidos. Um padrão de corte j é definido por um vetor $a_j = (a_{1j}, a_{2j}, \dots, a_{mj})$, em que cada a_{ij} é um número inteiro não negativo que indica quantos segmentos do tipo i são produzidos quando uma bobina é cortada segundo o padrão j (GILMORE; GOMORY, 1963). Esse vetor deve satisfazer a restrição de capacidade

$$\sum_{i=1}^m a_{ij} l_i \leq L \quad (3)$$

, isto é, a soma dos comprimentos dos pedaços cortados não pode exceder o comprimento da bobina. Admite-se que, em um padrão viável, essa soma seja igual

ou menor que L ; onde qualquer diferença $L - \sum_i a_{ij}l_i$ corresponde ao retalho gerado ao usar o padrão j .

A decisão a ser tomada no CSP é quantas bobinas cortar em cada padrão j . Denotando por x_j o número de bobinas cortadas segundo o padrão j , o problema requer satisfazer toda a demanda de cada item i através dos padrões escolhidos, ou seja:

$$\sum_j a_{ij}x_j \geq d_i, \quad \text{para } i = 1, 2, \dots, m \quad (4)$$

, minimizando simultaneamente o desperdício total de material (GILMORE; GOMORY, 1963). Equivalentemente, pode-se definir o desperdício total como a sobra

de comprimento de todas as bobinas utilizadas: se $w_j = L - \sum_i a_{ij}l_i$ é o desperdício (sobra) ao aplicar o padrão j em uma bobina. Busca-se minimizar $\sum_j w_j x_j$ sujeito às restrições de demanda acima e $x_j \geq 0$ inteiro. Essa formulação capta o objetivo de produzir todos os segmentos necessários utilizando o mínimo possível de matéria-prima (ou seja, minimizando a parte não aproveitada das bobinas).

Para ilustrar, suponha que $L = 100$ (bobina-mãe de 100 unidades de comprimento) e existam dois tipos de itens: itens de comprimento $l_1 = 55$ e itens de comprimento $l_2 = 45$, com demandas d_1 e d_2 , respectivamente. Alguns padrões de corte possíveis seriam:

- Padrão 1: cortar 1 segmento de 55 e 1 segmento de 45 ($a_{1,1} = 1, a_{2,1} = 1$). Esse padrão ocupa exatamente $55 + 45 = 100$ unidades de comprimento, gerando retalho zero.
- Padrão 2: cortar 2 segmentos de 45 ($a_{1,2} = 0, a_{2,2} = 2$). Esse padrão consome $2 \times 45 = 90$ unidades de comprimento, deixando uma sobra de $100 - 90 = 10$ unidades (10% de retalho).

- Padrão 3: cortar apenas 1 segmento de 55 ($a_{1,3} = 1, a_{2,3} = 0$). Nesse padrão, usa-se 55 do comprimento e sobram 45 unidades (45% de retalho).

Uma solução para o CSP consiste em escolher quantas bobinas serão cortadas em cada padrão. Por exemplo, poderíamos cortar x_1 bobinas seguindo o padrão 1, x_2 bobinas no padrão 2 e assim por diante, de modo que a soma dos segmentos produzidos de cada tipo alcance as demandas ($x_1 \cdot 1 + x_3 \cdot 1 = d_1$ para o item de 55, e $x_1 \cdot 1 + x_2 \cdot 2 = d_2$ para o item de 45, no exemplo acima). A qualidade de cada solução é medida pelo total de comprimento desperdiçado. O objetivo final é encontrar a combinação ótima de x_j que minimize esse desperdício total, atendendo às demandas.

A partir dessas definições, o CSP pode ser formulado como um modelo de PLI, no qual se busca determinar quantas bobinas devem ser cortadas segundo cada padrão, de modo a atender toda a demanda com o menor consumo total de bobinas, o que implica indiretamente a redução do desperdício de material. Essa formulação corresponde ao modelo clássico proposto por Gilmore e Gomory (1963), amplamente adotado na literatura de Pesquisa Operacional.

O modelo clássico de PLI do CSP unidimensional pode ser expresso como:

$$\min \sum_j x_j \quad (5)$$

sujeito a

$$\sum_j a_{ij} x_j \geq d_i, \quad \forall i = 1, 2, \dots, m, \quad x_j \in \mathbb{Z}_+, \quad \forall j \quad (6)$$

, em que x_j representa o número de bobinas cortadas segundo o padrão j , a_{ij} indica a quantidade de itens do tipo i produzidos pelo padrão j , e d_i corresponde à demanda do item i .

2.2.2 Métricas de Avaliação (Desperdício, Número de Padrões, Tempo Computacional)

A literatura adota três indicadores centrais para mensurar a eficiência de uma solução de corte (DYCKHOFF; FINKELSTEIN, 1991). O primeiro é o desperdício, ou retalho, expresso pela fração do comprimento da bobina-mãe que permanece sem aproveitamento após o atendimento integral da demanda (GILMORE; GOMORY, 1963). Tipicamente calcula-se essa métrica como

$$W = \frac{\text{sobra total}}{\text{comprimento total consumido}} \quad (7)$$

, representando a proporção do material que foi perdido. Uma solução ideal teria $W = 0$ (nenhum desperdício), mas isso raramente é possível em instâncias não triviais. Reduzir o desperdício traz benefícios econômicos diretos, pois significa usar menos matéria-prima para produzir os mesmos pedidos, além de benefícios ambientais (menos sucata gerada). Em muitos estudos do CSP, minimizar o desperdício é o objetivo principal e chega-se a economias consideráveis na ordem de 7% ao otimizar esse critério (FANG et al., 2023).

O segundo critério refere-se ao número de padrões distintos aplicados, pois cada novo padrão exige setup adicional, eleva o esforço de programação e impacta a logística interna de estocagem (WÄSCHER; GAU, 1996). Esse indicador mede a complexidade operacional da solução de corte. Em termos práticos, se a solução determina o uso de muitos padrões diferentes, significa que frequentemente será preciso ajustar a máquina de corte para um novo arranjo (trocar facas, recalibrar espaçamentos, etc.), o que toma tempo e pode interromper o fluxo produtivo. Por outro lado, uma solução que utiliza poucos padrões repetidamente simplifica a operação e o planejamento. Assim, às vezes aceita-se um pequeno aumento no desperdício se isso permitir usar significativamente menos padrões. Há, portanto, um *trade-off* entre a eficiência do material e a simplicidade operacional. Wäscher & Gau (1996) destacam que, ao avaliar heurísticas de corte, deve-se considerar não apenas o percentual de aproveitamento, mas também quantos padrões diferentes são gerados, pois esse número afeta diretamente a viabilidade prática de implementação da solução em fábrica.

O terceiro indicador é o tempo computacional necessário para gerar os padrões e resolver o modelo, métrica crucial em ambientes de replanejamento contínuo, nos quais as instâncias devem ser solucionadas em poucos minutos para não atrasar a produção (PITOMBEIRA-NETO; PRATA, 2019). Em ambientes industriais dinâmicos (horizonte rolante, por exemplo), o planejamento de corte pode precisar ser refeito com frequência, incorporando novos pedidos e mudanças de previsão de demanda (POLDI; ARENALES, 2010). Nesse contexto, mesmo que um método produza cortes ligeiramente melhores (menos desperdício), ele pode não ser útil se demorar horas para rodar, pois quando a solução ficasse pronta, já teria surgido uma nova lista de pedidos ou a linha de produção ficaria ociosa aguardando o plano. Assim, tempo de execução é uma restrição prática: soluções de corte precisam ser computadas em tempo hábil. De maneira geral, considera-se desejável que o algoritmo forneça um plano em poucos minutos ou segundos, a depender da frequência de reotimização e do tamanho da instância. Pitombeira-Neto e Prata (2019) mostram que, ao incorporar múltiplos períodos (horizonte longitudinal) em um modelo exato de corte, o tamanho do problema cresce exponencialmente e rapidamente ultrapassa as capacidades computacionais em instâncias realistas, reforçando a necessidade de métodos rápidos (heurísticos ou de aprendizado) para uso operacional. Em resumo, além de soluções de boa qualidade, é imprescindível que o método de solução seja compatível com as janelas de tempo disponíveis no PCP.

Em síntese, a avaliação de um plano de corte envolve múltiplos critérios: minimizar o desperdício, utilizar poucos padrões e obter a solução rapidamente (WÄSCHER; HAUSSNER; SCHUMANN, 2007). Esses critérios nem sempre estão alinhados – por exemplo, o plano com mínimo desperdício pode usar muitos padrões ou demorar muito para ser encontrado. Portanto, na prática deve-se balancear essas métricas conforme as prioridades do ambiente industrial.

2.3 APLICAÇÕES DE RL AO CSP

Nesta seção, exploram-se as abordagens de RL aplicadas ao CSP, enfocando os desafios de modelagem do problema como um Processo de Decisão de Markov e o design de funções de recompensa que equilibrem simultaneamente retalhos e níveis de estoque. Até recentemente, eram escassos os estudos unindo RL e CSP; contudo, trabalhos recentes (PITOMBEIRA-NETO; MURTA, 2021; SU et al., 2023) sugerem

que essa combinação é promissora. Pitombeira-Neto e Murta (2021) propuseram uma formulação do CSP estocástico como um MDP de horizonte infinito e desenvolveram um algoritmo de Iteração Aproximada de Políticas para resolvê-lo, enquanto Su et al. (2023) aplicaram um algoritmo ator-crítico (*Advantage Actor-Critic*) em um cenário de CSP estocástico com horizonte finito. Ambas as iniciativas buscam verificar se um agente de RL pode igualar ou superar as estratégias tradicionais de corte, especialmente em contextos dinâmicos onde métodos exatos enfrentam dificuldade.

2.3.1 Desafios e Oportunidades na Integração RL–CSP

A integração de métodos de RL ao CSP enfrenta desafios significativos devido ao crescimento exponencial dos espaços de estado e ação quando cada padrão de corte é tratado como uma opção de decisão (SU et al., 2023). Concretamente, ao se ter dezenas de tipos de itens, o número de padrões de corte distintos (ações possíveis) torna-se elevado – inviabilizando uma abordagem direta onde o agente tentaria estimar um valor para cada ação individualmente. Cada estado do sistema (estoques atuais, demandas futuras) também possui dimensionalidade elevada, pois é definido pela combinação das quantidades de diversos itens em estoque e possivelmente informações das demandas nos períodos seguintes. Esse volume de possibilidades torna o uso ingênuo de RL (por exemplo, com tabelas Q explícitas) impraticável. Uma oportunidade de pesquisa para mitigar esse problema é desenvolver representações compactas ou estruturadas para ações e estados.

Além disso, a natureza estocástica da demanda em horizonte rolante exige que o agente equilibre exploração e aproveitamento adequadamente, sem sobrecarregar o simulador com episódios excessivos (PITOMBEIRA-NETO; MURTA, 2021). Em outras palavras, é preciso definir estratégias de treinamento que permitam ao agente explorar um conjunto suficiente de diferentes políticas de corte (padrões usados em sequência) para descobrir alternativas eficientes, mas também aproveitar o conhecimento já obtido, concentrando as simulações nas políticas mais promissoras. Encontrar esse equilíbrio não é trivial e envolve parâmetros sensíveis: uma taxa de exploração muito alta (por exemplo, sempre escolher ações aleatórias com alta probabilidade) pode resultar em um tempo de treinamento muito longo e instável; já uma exploração muito baixa (o agente fica guloso cedo demais) pode fazer com que ele nunca descubra certas sequências de cortes vantajosas. Pitombeira-Neto e Murta

(2021) destacam que calibrar esse equilíbrio foi crucial em seus experimentos: por exemplo, eles controlaram o número de episódios de treinamento e o critério de parada de forma a evitar treinar o agente indefinidamente sem ganhos significativos. Em termos práticos, eles limitaram o total de iterações e observaram a convergência da recompensa média para decidir quando interromper o treinamento. Isso sugere que, na integração RL–CSP, deve-se ter cuidado para não “sobre-explorar” o ambiente – o que consumiria enorme poder computacional – mas também evitar convergir muito rapidamente para uma política potencialmente subótima. Estratégias como redução gradual da exploração (valor de ϵ decrescente ao longo do treinamento) ou técnicas de *early stopping* no treinamento podem ser úteis para abordar esse desafio.

A definição de uma função de recompensa que penalize simultaneamente o retalho e os níveis de estoque requer cuidadosa engenharia de feedback. Diferentemente de problemas clássicos de RL, nos quais a recompensa é naturalmente definida (por exemplo, pontuação em um jogo), no CSP precisa-se formular uma função de custo que traduza objetivos comerciais em um número a ser maximizado (ou custo a ser minimizado). É comum modelar a recompensa imediata como o negativo do retalho gerado em cada período menos uma penalização proporcional ao inventário final daquele período (para desencorajar excesso de produção) (ZHANG; YANG; BASAR, 2021). No entanto, os pesos atribuídos a cada componente são críticos: se a penalização por estoque for muito baixa, o agente poderá privilegiar cortes com mínimo retalho imediato mesmo que isso gere um grande acúmulo de produto (pois não é suficientemente penalizado por isso); por outro lado, se penalizarmos demais o estoque, o agente tenderá a cortar menos do que poderia, deixando demandas não atendidas ou forçando cortes emergenciais ineficientes (VRABIE; LEWIS; WANG, 2013). A modelagem adequada da recompensa muitas vezes é resultado de iteração experimental. Requer testar diferentes combinações de penalidades até que o comportamento observado do agente reflita o *trade-off* desejado entre retalho e estoque. A definição do que é considerado desejável no contexto do problema não decorre de uma noção abstrata de otimalidade, mas da tradução de objetivos operacionais em critérios mensuráveis. Em ambientes reais, o custo total raramente pode ser expresso por uma função única e fixa, sendo comum a existência de *trade-offs* entre desperdício de material e níveis de estoque. Assim, a função de recompensa não visa garantir uma política globalmente ótima, mas refletir

preferências operacionais explícitas, cuja adequação é avaliada empiricamente por meio do desempenho obtido e da comparação com métodos de referência. O ajuste de pesos, embora exija cuidado, faz parte do processo de modelagem e não elimina a validade da abordagem, desde que seus efeitos sejam analisados de forma sistemática. Por exemplo, pode-se atribuir um peso 10 vezes maior ao desperdício do que ao estoque nas penalizações; assim, o agente tenderá a evitar ao máximo o retalho, tolerando um pouco de estoque extra se necessário. Por outro lado, se forem atribuídos pesos equivalentes para custo de retalho e custo de estoque, o agente buscará equilibrar as duas metas, possivelmente aceitando gerar um pequeno retalho se isso evitar um excesso de inventário. Essa necessidade de ajustar a função de recompensa adiciona mais um nível de complexidade ao desenvolvimento do agente RL no CSP, mas quando bem-sucedida, resulta em um sinal de aprendizado que guia o agente a decisões equilibradas. Em problemas com restrições de capacidade muito rígidas, o Aprendizado por Reforço pode apresentar dificuldades de aprendizado, não sendo necessariamente a abordagem mais adequada sem adaptações adicionais. (VRABIE; LEWIS; WANG, 2013)

Em suma, projetar um agente de RL eficaz para o problema de corte de bobinas requer abordar criativamente as dificuldades acima: reduzir o espaço de decisão explorado (via representações especializadas), balancear exploração no treinamento e calibrar cuidadosamente a função de recompensa. Esses desafios não são triviais, mas tampouco intransponíveis. Conforme discutido a seguir, já existem resultados que demonstram que, com as devidas soluções de modelagem, o RL pode de fato alcançar desempenhos impressionantes no CSP (MOHAMMED et al., 2020).

2.3.2 Comparação com Modelos Clássicos (Benchmarking e Resultados Reportados)

A comparação entre abordagens de RL e modelos clássicos de PLI é indispensável para avaliar ganhos reais em problemas de corte: não basta reduzir desperdício em um cenário pontual; é preciso comprovar robustez ao longo do tempo, estabilidade de treinamento e compatibilidade com janelas operacionais do PCP (ZHANG; YANG; BASAR, 2021). Nesse panorama, emergem duas linhas recentes e complementares. De um lado, a formulação pioneira de Pitombeira-Neto e Murta (2022), que coloca o CSP dinâmico sob a ótica de um MDP e evidencia o valor de

políticas não míopes. De outro, a contribuição de Su et al. (2023), que internaliza algoritmos ator-crítico modernos e adapta o treinamento às particularidades do corte, aproximando-se do desenho metodológico adotado nesta pesquisa. A seguir, descrevem-se essas contribuições e, por fim, delinea-se o posicionamento da proposta atual frente a ambas.

2.3.2.1 Contribuições de Pitombeira-Neto e Murta (2022)

O estudo de Pitombeira-Neto e Murta (2022) representa um ponto de inflexão ao conceber o CSP estocástico como um MDP de horizonte infinito descontado. Nessa leitura, o estado agrega, sobretudo, os níveis de estoque por comprimento disponíveis a cada época; a ação corresponde à seleção de um padrão de corte aplicável; e o custo imediato combina penalizações por retalho e por manutenção de estoque, preservando o trade-off estrutural do problema. A função objetivo passa a ser minimizar o custo acumulado descontado, isto é, maximizar o retorno negativo das penalidades ao longo do tempo:

$$J^\pi = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t c(s_t, a_t) \right] \quad (8)$$

onde $c(s_t, a_t)$ agrega retalho e estoque e $\gamma \in (0, 1)$ assegura a convergência. Com esse enquadramento, decisões locais deixam de ser isoladas: produzir um pouco mais hoje pode reduzir o retalho futuro; produzir um pouco menos pode evitar estoques onerosos, e a política ótima deve internalizar esse balanço intertemporal.

Para resolver o problema em escala viável, os autores recorreram à Iteração API com aproximação linear. A avaliação de política é feita por projeção da equação de Bellman em uma base de funções (polinomial e de Fourier), estimada a partir de amostras geradas por simulação. A melhoria de política, por sua vez, utiliza o método de entropia cruzada, filtrando padrões de corte candidatos conforme seu desempenho amostral. Esse desenho evita a necessidade de conhecer o modelo de transição exato e dribla, parcialmente, a explosão combinatória do espaço de ações, ao passo que mantém as ações factíveis no domínio do corte (sem violar a capacidade da bobina

nem produzir itens “negativos”). O resultado é um ciclo iterativo de avaliação-melhoria que converge para políticas estáveis no recorte experimental analisado.

Empiricamente, Pitombeira-Neto e Murta (2022) relatam reduções expressivas de custo médio (ordem de grandeza de até 80% frente a políticas míopes que otimizam apenas o período corrente), com melhor controle dos estoques sob demanda volátil. A contribuição é dupla: demonstra que o CSP dinâmico beneficia-se de políticas que “olham para frente”; e a estrutura MDP é adequada para capturar o encadeamento entre períodos. As limitações também são claras: a API com funções de base exige engenharia manual de representações; a calibragem de hiperparâmetros é sensível; e a escalabilidade para instâncias maiores fica condicionada à capacidade dessas bases em representar bem estados de alta dimensão. Em síntese, trata-se de um marco conceitual que abre caminho para metodologias de RL mais modernas, orientadas a representação automática (*deep RL*).

2.3.2.2 *Contribuições de Su et al.*

Su et al. (2023) avançam metodologicamente ao adotar algoritmos ator-crítico com aprendizado profundo. A escolha é coerente com a natureza combinatória do problema: redes neurais substituem funções de base pré-definidas e aprendem representações distribuídas do estado (estoques, posições no horizonte, sinais auxiliares), enquanto o ator parametriza diretamente a política estocástica de seleção de ações. Essa arquitetura reduz a variância do gradiente por meio da função vantagem e traz melhorias de estabilidade no treinamento, aproximando a prática do estado da arte em RL para controle sequencial.

Um diferencial importante do estudo é a adaptação do processo de treinamento às restrições de corte. Os autores descrevem um agendamento do fator de desconto em duas fases, inicialmente privilegiando a satisfação de demanda (evitar faltas e padrões inviáveis) e, numa etapa posterior, ajustando o foco para a minimização fina dos custos (retalho e estoque). Complementarmente, introduzem o término antecipado de episódios ao detectar ações inválidas, aplicando penalizações fortes que “ensinam” ao agente a respeitar a viabilidade operacional sem precisar codificar regras rígidas na ação. Tais mecanismos, inspirados em boas práticas de engenharia

de RL, aceleram a aprendizagem de políticas factíveis e diminuem o tempo até a estabilização.

Nos resultados, as políticas convergem com rapidez superior às alternativas baseadas em aproximação linear, gerando planos que equilibram estoque e retalho com desempenho consistentemente melhor que referências simples (políticas gulosas ou aleatórias). A inferência, uma vez treinado o agente, ocorre em tempo praticamente instantâneo, aspecto valioso em ambientes de replanejamento frequente. Ainda que o trabalho não se compare exaustivamente a PLI em instâncias grandes (pela própria dificuldade de solução exata em horizonte dinâmico), os achados reforçam que a adoção de ator-crítico profundo é uma via promissora para escala e robustez, desde que a função de recompensa seja bem calibrada ao trade-off operacional do corte.

2.4 FORMULAÇÕES CLÁSSICAS PARA O CSP

A formulação clássica do CSP baseia-se na representação por padrões de corte, na qual cada padrão descreve uma combinação viável de peças que preenche a bobina-mãe. Essa estrutura permite modelar o problema como um caso de particionamento, resolvido por Programação Linear Inteira. A seguir, apresentam-se essas formulações e suas extensões com variáveis binárias para restrições operacionais.

2.4.1 Modelo de corte como problema de particionamento

Em um algoritmo típico de geração de colunas para o CSP, começa-se resolvendo um problema-mestre restrito, considerando apenas um subconjunto inicial de padrões $P' \subset P$ (GILMORE; GOMORY, 1961). Esse problema-mestre restrito é uma versão reduzida da PLI apresentada (frequentemente relaxada como programação linear contínua para fins de otimização contínua inicial). Após resolvê-lo, obtém-se uma solução ótima provisória junto com preços duais associados às restrições de demanda i . Intuitivamente, cada preço dual indica o quanto reduziria o objetivo (número de bobinas) se pudéssemos aumentar em uma unidade a oferta do item i – ou seja, reflete o “valor” de se obter mais uma peça do tipo i (GILMORE; GOMORY, 1961).

De posse desses valores duais, formula-se um subproblema de geração de colunas, que no caso do CSP corresponde a um problema de mochila unidimensional. Neste subproblema, busca-se um novo padrão de corte com potencial para melhorar a solução do mestre: cada item i recebe um peso (ou valor) igual ao seu preço dual, e o subproblema procura a combinação de itens que maximiza a soma desses valores sem exceder o comprimento L da bobina. Em outras palavras, o subproblema tenta montar um padrão que tenha o maior “lucro” possível em termos de valor dual. Se o valor total encontrado pelo subproblema exceder 1, que é o custo de se utilizar uma bobina adicional no objetivo, significa que esse padrão novo possui custo reduzido negativo – isto é, incorporá-lo ao conjunto de colunas do mestre pode diminuir o valor objetivo (reduzir o número de bobinas necessárias). Nesse caso, o novo padrão é adicionado ao problema-mestre (a coluna correspondente é inserida na matriz) e o mestre é resolvido novamente (GILMORE; GOMORY, 1963).

Esse procedimento iterativo prossegue, alternando entre resolver o mestre restrito e gerar novas colunas via subproblema, até que nenhum padrão viável apresente custo reduzido negativo. A ausência de melhoria indica que a solução atual do problema-mestre é ótima (para a relaxação linear) considerando todos os padrões possíveis de forma implícita. Por fim, uma vez que o conjunto relevante de padrões tenha sido identificado por meio da relaxação linear, pode-se obter a solução inteira do CSP impondo a integridade das variáveis x_j . Essa formulação e algoritmo de PLI por geração de colunas estabelecem o referencial clássico de solução exata para o CSP unidimensional.

2.4.2 Modelo de Corte formulado como PLI estático em padrões pré-gerados

Ao contrário da abordagem de geração de colunas da Seção 2.4.1, aqui considera-se um catálogo fixo de padrões. Além das abordagens dinâmicas de geração de colunas (GILMORE; GOMORY, 1961; DESAULNIERS; DESROSIERS; SOLOMON, 2005), a literatura também apresenta formulações estáticas do Problema de Corte de Bobinas, nas quais se considera um conjunto fixo e previamente enumerado de padrões de corte. Nessa estrutura, cada padrão descreve uma combinação viável de peças que preenche a bobina-mãe, e o PLI busca determinar quantas vezes cada padrão deve ser utilizado para satisfazer a demanda conhecida

de cada item (WÄSCHER; HAUSSNER; SCHUMANN, 2007; MARTELLO; TOTH, 1990).

Formalmente, denotando por $a_{i,p}$ o número de peças do tipo i produzidas quando o padrão p é aplicado, e por $x_p \in \mathbb{Z}_+$ o número de bobinas cortadas segundo o padrão p , a formulação geral do modelo estático pode ser expressa como:

$$\min \sum_{p \in \mathcal{P}} c_p x_p \quad \text{sujeito a} \quad \sum_{p \in \mathcal{P}} a_{i,p} x_p \geq d_i, \quad \forall i \in \mathcal{I}, \quad x_p \in \mathbb{Z}_+, \quad \forall p \in \mathcal{P}. \quad (9)$$

O coeficiente c_p representa o custo associado ao padrão p , frequentemente relacionado ao desperdício de material ou a outros custos de operação (DYCKHOFF, 1990; HINXMAN, 1980). O conjunto $\mathcal{P}$ é finito e conhecido a priori, sendo obtido por procedimentos de enumeração que geram todas as combinações viáveis de cortes dentro do comprimento padrão da bobina-mãe.

Essa formulação é denominada PLI estática porque todas as colunas (padrões) são consideradas explicitamente desde o início, resolvendo-se o problema inteiro-misto completo sem etapa de precificação. Embora essa abordagem possa se tornar computacionalmente cara quando o número de padrões é grande, ela é adequada em situações nas quais o catálogo de padrões é de tamanho moderado ou quando se deseja avaliar políticas de corte sob um conjunto fixo de alternativas (LÜBBECKE; DESROSIERS, 2005).

Dessa forma, o modelo PLI estático preserva a estrutura clássica do problema de corte e constitui uma referência determinística fundamental na literatura para comparação com métodos heurísticos e de Aprendizado por Reforço (SUTTON; BARTO, 2018).

3 METODOLOGIA

Este capítulo descreve o desenho metodológico adotado para investigar o problema de corte de bobinas em ambiente dinâmico. Primeiro, em 3.1 Classificação da Pesquisa, enquadra-se o estudo quanto à natureza, abordagem, objetivos e procedimentos. Em seguida, a subseção 3.2 Procedimento Metodológico apresenta o encadeamento de etapas que estrutura o trabalho: modelagem de referência, desenvolvimento da abordagem de aprendizado por reforço e protocolo de comparação. Na sequência, a subseção 3.3 Modelo Determinístico (PLI) formaliza o problema estático de seleção de padrões pré-gerados que servirá de base. A subseção 3.4 Ferramentas e Plataformas registra o ambiente computacional utilizado. Por fim, a subseção 3.5 Encaminhamento para a Formulação do Problema conecta a metodologia às especificações formais detalhadas no capítulo seguinte.

3.1 CLASSIFICAÇÃO DE PESQUISA

A pesquisa será desenvolvida de maneira sistemática, organizada em fases complementares voltadas ao atendimento dos objetivos específicos., dividida em três fases que, em conjunto, compõem a solução do problema de pesquisa.

Conforme Silva e Menezes (2000), a classificação da pesquisa pode ser analisada sob quatro dimensões: natureza, abordagem, objetivos e procedimentos técnicos.

- Natureza (aplicada) – O estudo gera conhecimento para solução de problema industrial concreto, o corte de bobinas em linhas CTL (VERGARA, 2016).
- Abordagem (quantitativa) – A avaliação baseia-se em indicadores formais (retalho, estoque, tempo de execução), obtidos por simulação e análise estatística (SAUNDERS; LEWIS; THORNHILL, 2019).
- Objetivos (exploratórios-descritivos) – A investigação descreve o comportamento de diferentes métodos e explora o potencial do RL para o CSP, campo ainda incipiente (PITOMBEIRA-NETO; MURTA, 2022; SU et al., 2023).
- Procedimentos técnicos – O trabalho combina pesquisa bibliográfica, modelagem matemática, treinamento de agentes RL.

A unidade de análise é o processo decisório diário de corte em linha CTL sob regime MTS; a temporalidade é longitudinal, pois se avaliam múltiplos períodos simulados. O ambiente de pesquisa caracteriza-se como quase-experimental *in silico* (LAKATOS; MARCONI, 2022), permitindo controle de variáveis e replicabilidade. Para tanto, serão utilizados dados sintetizados, gerados a partir de distribuições estatísticas fundamentadas na literatura (LAW; KELTON, 2021) e em parâmetros industriais típicos, permitindo avaliar primeiramente a robustez teórica do modelo. A aplicação em ambiente industrial poderá ser investigada em trabalhos futuros.

3.2 PROCEDIMENTO METODOLÓGICO

O procedimento metodológico desta pesquisa divide-se em três etapas sequenciais, cada qual orientada a cumprir um objetivo específico previamente definido. Esse encadeamento de fases garante que a fundamentação teórica, o desenvolvimento da solução baseada em RL e a comparação com modelos clássicos ocorram de forma coerente e incremental. A seguir, cada etapa é apresentada em detalhe.

3.2.1 Etapa 1- Como foi feito: da revisão à implementação

A primeira etapa compreende as atividades de base teórica e técnica do estudo.

1. Revisão da literatura: realizou-se um levantamento sistemático das formulações do CSP e das principais abordagens de PLI (GILMORE; GOMORY, 1961; MARTELLO; TOTH, 1990; WÄSCHER; HAUSSNER; SCHUMANN, 2007). Também foram analisadas contribuições recentes que aplicam técnicas de RL em problemas combinatórios e produtivos (PITOMBEIRA-NETO; MURTA, 2022; FANG et al., 2023; SU et al., 2023). O levantamento bibliográfico concentrou-se em bases de dados científicas consolidadas, sendo elas *Web of Science*, *ScienceDirect* e *IEEE Xplore*, priorizando artigos de periódicos e conferências com relevância nas áreas de Pesquisa Operacional, Otimização e Inteligência Artificial. Os trabalhos selecionados foram aqueles com aderência direta ao problema de corte de

bobinas, reconhecimento na literatura e contribuição metodológica relevante para o contexto analisado.

2. Planejamento experimental: definiram-se as métricas de desempenho, horizonte temporal (diário), parâmetros de demanda e critérios de comparação, conforme diretrizes de experimentação computacional (LAW; KELTON, 2021; SAUNDERS; LEWIS; THORNHILL, 2019).
3. Ambiente computacional: a implementação foi conduzida em *Python 3* por sua ampla aplicação em pesquisa científica e suporte a bibliotecas de código aberto (VANDERPLAS, 2016), utilizando a IDE *Visual Studio Code*, em sistema operacional *Windows*. As principais ferramentas utilizadas foram:
 - a. *NumPy* para operações vetoriais e álgebra linear;
 - b. *Pandas* para manipulação e análise de dados;
 - c. *Matplotlib* para visualização de resultados;
 - d. *Gymnasium* para padronização da interface agente–ambiente;
 - e. *Stable Baselines3* para implementação de algoritmos de Aprendizado por Reforço, como PPO;
 - f. *Solver de PLI* conforme diretrizes de DYCKHOFF (1990) para modelos determinísticos.
4. Implementação inicial: foram desenvolvidas as rotinas de geração de instâncias, simulação e coleta de resultados, validando consistência dimensional e coerência entre variáveis, conforme recomendações de SARGENT (2013).

3.2.2 Etapa 2 - O que foi feito: desenvolvimento e estruturação dos modelos

A segunda etapa teve como objetivo principal o desenvolvimento dos modelos computacionais que sustentam a comparação entre abordagens de otimização determinística e aprendizado por reforço. Após o embasamento teórico consolidado na Etapa 1, esta fase concentrou-se na implementação prática, no desenho do ambiente de simulação e na definição dos componentes necessários à análise experimental.

Inicialmente, foi conduzida uma revisão técnica complementar da literatura sobre modelagem de processos decisórios sequenciais e métodos de aprendizado por reforço, com ênfase em formulações de processos de decisão de Markov

(SUTTON; BARTO, 2018; PUTERMAN, 1994). Essa revisão orientou a estrutura lógica e os parâmetros adotados no ambiente de teste.

Em seguida, foi implementado o ambiente de simulação, capaz de representar o processo de corte ao longo de múltiplos períodos, considerando estoques, demandas e decisões de produção.

Posteriormente, foram construídos os modelos determinístico e de aprendizado, garantindo que ambos utilizassem as mesmas instâncias de entrada e premissas operacionais para permitir comparabilidade justa. O modelo determinístico foi formulado como uma Programação Linear Inteira (PLI) estática, resolvida de forma independente em horizonte rolante diário, enquanto o modelo de aprendizado foi configurado com base em algoritmos ator-crítico, particularmente o PPO (*Proximal Policy Optimization*), conforme descrito por Schulman et al. (2017).

Para ambas as abordagens, foi desenvolvida uma rotina de simulação integrada, capaz de:

1. Gerar demandas sintéticas;
2. Atualizar o estado do sistema após cada decisão de corte;
3. Registrar métricas de desempenho (desperdício, estoque médio e atendimento);
4. Exportar os resultados em formato CSV para posterior análise.

A estrutura computacional do projeto foi organizada em módulos independentes, leitura de parâmetros, ambiente de simulação, resolução dos modelos e coleta de métricas, assegurando clareza e modularidade no código. Ambos os agentes, o determinístico (PLI) e o de Aprendizado por Reforço (PPO), foram simulados sob as mesmas condições experimentais, incluindo o mesmo conjunto de demandas, limites de capacidade, horizonte temporal e parâmetros operacionais. Assim, a única diferença entre eles reside na forma de tomada de decisão: enquanto o PLI escolhe padrões por otimização exata a cada dia, o PPO aprende uma política de decisão adaptativa ao longo dos episódios.

As formulações matemáticas completas, as recompensas, restrições e parâmetros utilizados serão apresentadas de forma detalhada no Capítulo 4, que descreve os modelos finais.

3.2.3 Etapa 3, Comparação entre os dois modelos

A terceira etapa corresponde à fase de comparação entre os modelos, em que se avaliam os resultados obtidos pelo modelo determinístico (PLI estático) e pelo agente de Aprendizado por Reforço (PPO) sob as mesmas condições experimentais. Essa etapa tem o papel de verificar até que ponto o agente de aprendizado consegue reproduzir, ou superar, o desempenho do modelo clássico, considerando indicadores operacionais e de consistência.

Ambos os modelos foram executados em cenários idênticos, utilizando o mesmo conjunto de demandas, limites de capacidade diária, horizonte temporal, custos e restrições. O horizonte de simulação é rolante e diário, o que significa que a cada dia o sistema é atualizado com novas demandas, estoques e decisões. Assim, a única diferença entre os experimentos está na forma de tomada de decisão: o PLI decide com base em otimização exata a cada período, enquanto o PPO aplica uma política aprendida ao longo do treinamento.

O protocolo de análise envolve uma comparação direta e detalhada entre os resultados obtidos em cada abordagem, considerando os seguintes aspectos:

1. Desempenho operacional:

- Percentual de retalho (sucata) gerado por dia e acumulado;
- Nível médio de estoque ao longo do horizonte de planejamento;
- Taxa de atendimento de demanda (número de pedidos satisfeitos versus total de pedidos);

2. Estabilidade e consistência:

- Avaliação da variação dos resultados em múltiplas execuções com diferentes sementes aleatórias;
- Análise de tendência temporal (como os resultados se comportam ao longo dos dias).

3. Visualização e interpretação:

- Foram construídos gráficos comparativos de evolução de custo, estoque e desperdício;
- Tabelas resumo trarão valores comparativos médios de cada métrica por cenário (E5 e E20).

4. Cenários de teste:

- Cenário E5: composto por cinco tipos de produtos (SKUs), com menor variabilidade e demanda mais previsível, representando um ambiente de baixa complexidade;
- Cenário E20: composto por vinte SKUs, com maior variabilidade e sobreposição de padrões,

3.3 MODELO DETERMINÍSTICO (PLI)

A formulação clássica do CSP, proposta por Gilmore e Gomory, modela o corte de bobinas como um problema-mestre de PLI, no qual cada padrão de corte viável corresponde a uma coluna de uma grande matriz de coeficientes. Nessa matriz, cada linha i representa um tipo de item de comprimento $\underline{l}_i$ demandado, e os coeficientes $\underline{a}_{ij}$ indicam quantas peças do item i aparecem no padrão de corte j . Assim, ao escolher determinados padrões, o modelo decide quantas bobinas-mãe serão cortadas segundo cada padrão (variáveis de decisão $\underline{x}_j$), de modo a atender todas as demandas com o menor desperdício possível.

Ressalta-se que essa formulação corresponde a um modelo estático do CSP, no qual a demanda é considerada de forma agregada, não havendo distinção explícita entre períodos de produção ou atendimento diário. O objetivo dessa PLI é minimizar o número total de bobinas utilizadas (o que implica indiretamente a redução do retalho no contexto clássico e estático do CSP, no qual não se considera reaproveitamento intertemporal de sobras). Formalmente, seja $\underline{P}$ o conjunto de todos os padrões de corte possíveis. Definindo $\underline{x}_j$ como o número de bobinas cortadas segundo o padrão $\underline{j} \in \underline{P}$, a função objetivo e as restrições de demanda podem ser escritas como:

$$\min \sum_{j \in P} x_j \quad (10)$$

$$\sum_{j \in P} a_{ij} x_j \geq d_i, \quad \forall i = 1, 2, \dots, m \quad (11)$$

, onde $\underline{d}_i$ é a demanda (quantidade de segmentos) do item i . Adicionalmente, impõe-se que cada variável de decisão seja não-negativa e inteira:

$$x_j \in \mathbb{Z}_{\geq 0}, \quad \forall j \in P \quad (12)$$

Em palavras, a restrição de demanda garante que a quantidade produzida de cada comprimento i (soma das peças i cortadas em todos os padrões escolhidos) cubra a demanda d_i . O modelo assume, implicitamente, que cada padrão j é definido de forma a não exceder o comprimento da bobina ($\sum_i a_{ij}, l_i \leq L$), sendo qualquer espaço não utilizado interpretado como sobra (retalho). Minimizar $\sum_j x_j$ equivale a minimizar o total de bobinas consumidas – e, portanto, minimizar as sobras totais – já que o comprimento L de cada bobina é fixo e a soma dos comprimentos demandados $\sum_i d_i, l_i$ é constante.

No escopo deste trabalho optou-se pela adoção do modelo estático com padrões pré-gerados em vez da formulação com geração de colunas devido à sua maior simplicidade de implementação e estabilidade computacional, características recomendadas quando o conjunto de padrões é previamente conhecido e de tamanho gerenciável (ARENALES et al., 2015; WASCHER; HAUSSNER; SCHUMANN, 2007). A abordagem clássica de geração de colunas, embora eficiente para grandes instâncias, requer a resolução iterativa de subproblemas do tipo *knapsack* e o uso de informações duais para precificação de novas colunas (GILMORE; GOMORY, 1961; VANCE et al., 1994), o que eleva consideravelmente a complexidade algorítmica e o custo computacional. Nesse estudo, o conjunto de padrões foi pré-enumerado e filtrado segundo critérios geométricos e limites de desperdício (CHERRI et al., 2016), removendo todos os padrões com retalho maior a 100mm, possibilitando a resolução direta do problema-mestre como uma Programação Linear Inteira completa. Essa escolha também favorece a comparabilidade experimental com o agente de Aprendizado por Reforço, já que ambos operam sobre o mesmo catálogo fixo de padrões e sob as mesmas restrições, permitindo isolar o impacto da estratégia de decisão sobre o desempenho final.

3.4 FERRAMENTAS E PLATAFORMAS PARA IMPLEMENTAÇÃO

Para a implementação prática das abordagens descritas, adota-se exclusivamente o ecossistema Python 3, aproveitando bibliotecas consolidadas e

compatíveis com ambientes de pesquisa e produção. As principais ferramentas utilizadas são:

- *NumPy*: operações vetoriais e manipulação eficiente de matrizes, fundamentais para cálculos de funções de valor, gradientes e atualizações de política. Boa parte dos algoritmos de RL envolve álgebra linear (atualização de pesos de redes neurais, computação de valores Q , etc.) e o NumPy fornece essas operações de forma otimizada em baixo nível (em C), o que acelera enormemente o processamento. No contexto deste trabalho, as atualizações dos valores $Q(s, a)$ ou dos parâmetros da política são implementadas de forma vetorizada com *NumPy*, garantindo rapidez mesmo quando há muitas entradas para atualizar simultaneamente.
- *Pandas*: estruturação de dados em *DataFrames*, facilitando a organização de séries temporais de demanda, resultados de simulação e análises estatísticas. A biblioteca Pandas é útil para manipular tabelas de dados de forma simples, permitindo filtrar, agregar e transformar dados facilmente. No problema em questão, Pandas auxilia a armazenar e manipular, por exemplo, as sequências de demandas diárias geradas para simulação, os históricos de decisões do agente e métricas de desempenho (desperdício por episódio, uso de cada padrão, etc.). Isso torna a análise dos resultados pós-simulação mais ágil e confiável.
- *Matplotlib*: geração de gráficos para visualização de desempenho, comparação de métricas e monitoramento de treinamento de agentes. Durante o desenvolvimento e experimentos, é fundamental visualizar a evolução de certas métricas (como a recompensa média por episódio, o desperdício médio ao longo do tempo ou a distribuição de padrões utilizados). O Matplotlib permite criar esses gráficos de forma customizável.
- *Gymnasium*: *framework* que padroniza a interação agente–ambiente por meio dos métodos *reset()* e *step()*, permitindo criar e reproduzir cenários de aprendizado por reforço (BROCKMAN et al., 2016). Foi desenvolvido um ambiente customizado do CSP dinâmico conforme essa API, em que *reset()* inicializa estoques e demandas simuladas e *step(action)* aplica o padrão de

corte, atualiza o estado e calcula a recompensa. Essa padronização assegura compatibilidade com o *Stable Baselines3* e reprodutibilidade dos experimentos.

- *Stable Baselines3*: biblioteca em *PyTorch* que reúne implementações consolidadas de algoritmos de aprendizado por reforço, como PPO, A2C e DQN (SCHULMAN et al., 2017). Foi adotada por sua maturidade, eficiência e compatibilidade com o *Gymnasium*, permitindo treinar agentes de forma rápida e reprodutível sem necessidade de implementar manualmente todo o ciclo de otimização. Além disso, oferece flexibilidade para ajustar arquiteturas de rede e funções de recompensa, garantindo maior controle sobre os experimentos e confiabilidade nos resultados.
- *PuLP*: biblioteca em *Python* voltada à modelagem e resolução de problemas de Programação Linear e Inteira (MITCHELL; ROHENKOHL; REINELT, 2011). Foi utilizada para estruturar o modelo determinístico de corte de bobinas, permitindo definir variáveis, restrições e funções objetivo de forma declarativa e resolver o problema por meio de *solvers* abertos. A adoção do *PuLP* oferece um equilíbrio entre simplicidade e flexibilidade, integrando-se facilmente com outras bibliotecas do ecossistema *Python*, como *NumPy* e *Pandas*, e garantindo a reprodutibilidade dos resultados.

A escolha por essas ferramentas fundamenta-se em sua maturidade, ampla adoção pela comunidade científica e alta interoperabilidade, fatores que asseguram reprodutibilidade, flexibilidade e escalabilidade no desenvolvimento e avaliação de agentes de Aprendizado por Reforço aplicados ao CSP (VANDERPLAS, 2016; MCKINNEY, 2010; HUNTER, 2007; BROCKMAN et al., 2016; SCHULMAN et al., 2017). Todas são bibliotecas open-source amplamente utilizadas em pesquisa, o que facilita a comparação e validação independente de resultados, além de permitir integração contínua de melhorias pela comunidade acadêmica e industrial.

3.5 ENCAMINHAMENTO PARA A FORMULAÇÃO DO PROBLEMA

Este trabalho adota dois referenciais complementares para o CSP em ambiente dinâmico: (i) um baseline determinístico formulado como PLI estático com padrões

pré-gerados, resolvido dia a dia em horizonte rolante, e (ii) uma abordagem de Aprendizado por Reforço com PPO, na qual o problema é tratado como MDP com custos que penalizam retalho, estoque e não atendimento. O uso do PLI estático fornece uma referência clara e interpretável por meio de otimização exata sobre um catálogo fixo; o PPO, por sua vez, aprende uma política de decisão sequencial capaz de equilibrar objetivos ao longo do horizonte.

A formulação e a comparação são conduzidas sob condições experimentais idênticas (mesmas séries de demanda, mesma capacidade diária de produção de cortes, mesmos limites de estoque, mesmo horizonte e mesmas penalidades), garantindo comparabilidade direta entre as decisões produzidas por cada abordagem. O ambiente de simulação segue a interface Gymnasium, e o treinamento do agente utiliza Stable Baselines3, assegurando reprodutibilidade. Os Cenários E5 e E20 representam níveis crescentes de complexidade combinatória, permitindo avaliar robustez e sensibilidade à maior variedade de padrões.

No capítulo seguinte, serão formalizados: (a) o modelo PLI estático (variáveis, função-objetivo e restrições), (b) o MDP subjacente ao PPO (estado, ação, recompensa e fator de desconto), (c) os parâmetros experimentais (capacidade, limites de estoque, custos) e (d) os protocolos de avaliação, mantendo alinhamento estrito entre teoria, implementação e análise dos resultados.

4 FORMULAÇÃO DO PROBLEMA DE CORTE DINÂMICO COM APRENDIZADO POR REFORÇO

Este capítulo apresenta a formulação operacional do problema de corte de bobinas e a configuração utilizada nos experimentos. O modelo considera um horizonte de 300 dias, com decisões diárias e custos agregados por período, reproduzindo o comportamento de uma linha *cut-to-length* (CTL) sob regime make-to-stock (MTS). São definidos dois ambientes experimentais, E5 e E20, que compartilham o mesmo catálogo de padrões de corte gerado para uma bobina-mãe de largura efetiva de 1200 mm. No ambiente E20, padrões com retalho superior a 100 mm são removidos, reduzindo combinações ineficientes sem alterar a estrutura do problema (WÄSCHER; HAUSSNER; SCHUMANN, 2007).

A seguir, o capítulo organiza-se em seis partes: caracterização do fluxo diário e hipóteses de modelagem; representação sequencial do problema; definição do estado e espaço de ações; formulação da função de custo e recompensa; geração estocástica da demanda e ajuste de utilização; e parâmetros numéricos da implementação. Em conjunto, estas seções descrevem a especificação operacional do problema, que fundamenta a análise comparativa entre o modelo de Programação Linear Inteira (PLI) e o agente de Aprendizado por Reforço (PPO) no capítulo 5).

4.1 CARACTERIZAÇÃO DO PROBLEMA DE CORTE DE BOBINAS

Esta seção caracteriza o problema de corte unidimensional em ambiente produtivo, enfatizando a relação entre a geometria do corte, os catálogos de padrões viáveis, o atendimento da demanda diária e as restrições operacionais. Diferentemente de uma formulação estática, a versão aqui considerada é multiperíodo e inclui incerteza na demanda, razão pela qual a definição dos elementos físicos e das regras de operação precisa ser feita com precisão: as decisões de hoje afetam diretamente os estados e os custos de amanhã.

4.1.1 Definição geral do CSP 1D e elementos geométricos

Considera-se uma bobina-mãe que, quando desbobinada e preparada, fornece chapas de comprimento efetivo fixo L medido em milímetros. O conjunto de produtos

finais é formado por SKUs de larguras w_i , também em milímetros, assumindo-se $w_i < L$ para todo i . Um padrão de corte é um vetor inteiro não negativo $\mathbf{a} = (a_1, \dots, a_n)$ que representa quantas tiras do tipo i são obtidas ao cortar uma única chapa segundo a combinação definida por $\mathbf{a}$. A viabilidade geométrica básica exige $\sum_i a_i w_i \leq L$.

Define-se o retalho como $T(\mathbf{a}) = L - \sum_i a_i w_i$, sobra inevitável decorrente do arranjo discreto de larguras. Por requisitos de aproveitamento, adota-se um limite rígido $T(\mathbf{a}) \leq \bar{T}$, com $\bar{T} = 100 \text{ mm}$; na prática, esse limite exclui combinações com sobra excessiva e aproxima o conjunto de padrões das soluções com melhor utilização de material. O corte é unidimensional porque a decisão relevante se dá na direção transversal à bobina. Não há, portanto, decisões de empacotamento em duas dimensões; o foco está em quantas tiras de cada largura podem ser extraídas de uma chapa unitária, respeitando o comprimento L e o retalho máximo admitido $\bar{T}$.

4.1.2 Catálogo de padrões

O conjunto de padrões utilizados na simulação é pré-computado e disponíveis para o PLI e para o agente, garantindo comparabilidade. Esse catálogo resulta da enumeração de vetores $\mathbf{a}$ que atendam simultaneamente a $\sum_i a_i w_i \leq L$ e $T(\mathbf{a}) \leq \bar{T}$, no escopo deste trabalho foi adotado $\bar{T} = 100 \text{ mm}$. Em termos práticos, aplicam-se rotinas de viabilidade e de remoção de duplicidades, preservando combinações distintas que possam contribuir para o atendimento de SKUs específicos ao longo do horizonte de 300 dias. É importante distinguir aproveitamento geométrico de utilidade operacional no contexto do problema de corte de bobinas. Um padrão que gera menor retalho não é, necessariamente, superior quando se considera um ambiente multiproduto, sem *backlog* e com custos assimétricos de falta e excesso. Em determinados cenários, padrões com aproveitamento geométrico apenas moderado podem ser essenciais para recompor estoques de SKUs raros ou atender picos de demanda específicos, evitando perdas operacionais mais elevadas. Por essa razão, o catálogo de padrões não é filtrado exclusivamente por critérios de dominância geométrica. Em vez disso, busca-se manter diversidade de padrões sob um limite

máximo de retalho, garantindo cobertura adequada das diferentes demandas e evitando vieses que prejudiquem a representatividade por SKU.

4.1.3 Fluxo diário de produção, atendimento e estados

O sistema opera em dias discretos $t = 1, \dots, T$. No início de cada dia, existe um estoque de produtos acabados I_t que foi carregado do dia anterior, sem perdas por deterioração. Observa-se então a demanda do dia D_t , em unidades. O primeiro estágio do dia é o abatimento imediato da demanda pelo estoque existente, de modo que a demanda pendente por item é $\tilde{D}_t = \max(0, D_t - I_t)$. Em seguida, realiza-se o ciclo de produção por corte, em que o decisor escolhe um padrão a e uma quantidade inteira q de chapas a processar sob esse padrão, respeitando a capacidade diária de chapas e o limite de trocas de padrão. A produção resultante $P_t = q \cdot a$ é somada às disponibilidades do dia e alocada prioritariamente para atender $\tilde{D}_t$. A parte não consumida compõe o estoque de fim de dia $I_{t+1} = \max(0, I_t + P_t - D_t)$, que se torna o estoque inicial do próximo dia.

4.1.4 Custos operacionais e hierarquia de penalidades

Ao final de cada dia t , três componentes de custo são apurados. O custo de sucata depende do retalho acumulado nas chapas cortadas; se q chapas foram processadas com padrão a , o desperdício total é $W_t = q \cdot T(a)$ e o custo correspondente é $C_{\text{sucata},t} = c_s W_t$. O custo de estoque depende do volume em milímetros equivalente carregado para o dia seguinte; denotando por $\ell_i = w_i$ o comprimento por unidade do SKU i , o estoque em milímetros ao final do dia é

$$I_t^{\text{mm}} = \sum_i \ell_i I_{t,i}, \text{ com custo } C_{\text{estoque},t} = c_e I_t^{\text{mm}}.$$

O custo de perda de venda decorre da demanda não atendida no próprio dia: com falta $L_t^{\text{mm}} = \sum_i \ell_i \max(0, D_{t,i} - I_{t,i} - P_{t,i})$, tem-se $C_{\text{perda},t} = c_p L_t^{\text{mm}}$. Os valores associados às penalidades de sucata, estocagem e perda de venda não foram definidos a partir de uma formulação ótima ou universal, mas sim arbitrados de forma consciente durante a modelagem do ambiente. Esses parâmetros buscam refletir, de maneira aproximada, relações observadas em contextos industriais reais, nos quais o custo de armazenar um produto ao longo de

dias tende a ser significativamente inferior ao custo de descartá-lo, e o não atendimento da demanda representa a penalidade mais severa. Assim, a escolha dos pesos resulta da decisão do formulador do modelo, baseada em ordens de grandeza coerentes com a prática industrial, discretizadas no horizonte diário considerado. No escopo deste trabalho, o custo associado à perda de venda foi definido como arbitrariamente elevado, com o objetivo de induzir um aprendizado mais eficiente do agente de Aprendizado por Reforço, priorizando consistentemente o atendimento da demanda disponível em detrimento das demais decisões operacionais.

Além da hierarquia “perda de venda > retalho > estoque”, o ambiente adota um teto de estoque de 40 unidades por SKU. Quantidades acima do teto são automaticamente sucateadas, incorrendo custo de retalho. Essa política impossibilita acúmulo excessivo e evita que estoques desproporcionais distorçam o custo intertemporal.

4.1.5 Ritmo de decisão intra-dia e efeito do limite de setups

O ambiente dispõe de um orçamento de 8 blocos por dia, que representam os possíveis lotes de produção. Cada ação consome um bloco, independentemente da quantidade processada. O dia pode ser encerrado de três maneiras: quando o agente utiliza todos os blocos disponíveis, quando a capacidade diária de 50 chapas é esgotada, ou quando o próprio agente decide finalizar antecipadamente o ciclo diário por estratégia, visando reduzir custos ou evitar sobreprodução. Essa flexibilidade permite que políticas aprendidas explorem o equilíbrio entre produtividade, estoque e desperdício ao longo do horizonte.

Cada ação por bloco intra-dia é um par (padrão, quantidade) que define um lote de corte. O planejamento deve, portanto, otimizar simultaneamente a seleção do padrão e a duração do lote, respeitando o orçamento de 8 blocos diários e a capacidade de 50 chapas. Lotes longos tendem a gerar maior aproveitamento geométrico e reduzir o número de trocas, mas podem resultar em estoques elevados de SKUs de baixa demanda. Já lotes curtos aumentam a flexibilidade de atendimento, porém consomem rapidamente o orçamento de blocos e podem elevar o custo de retalho. Assim, a decisão ótima envolve um compromisso dinâmico entre produtividade, aproveitamento e risco de acúmulo, influenciado pelo estado de estoque e pela variabilidade da demanda.

4.1.6 Horizonte de 300 dias e intertemporalidade do objetivo

A adoção de um horizonte de $T = 300$ dias transforma a natureza do problema, que deixa de ser uma otimização estática e passa a depender de políticas intertemporais. Em horizontes curtos, políticas míopes tendem a priorizar a minimização do custo diário, evitando o acúmulo de estoque e a geração de retalho, mas acabam vulneráveis a perdas nos dias subsequentes, quando a demanda oscila acima da média. Em contrapartida, um horizonte estendido permite que políticas preditivas construam estoques de segurança moderados em períodos de baixa, suavizando a variabilidade e reduzindo o custo acumulado esperado. O efeito de propagação das decisões iniciais é central na comparação entre métodos.

4.2 HIPÓTESES E PRESSUPOSTOS DE MODELAGEM

A formulação computacional requer um conjunto de hipóteses que preservem a coerência física e tornem o problema tratável. O objetivo desta seção é explicitar as simplificações estruturais e probabilísticas que permitem representar o processo como um modelo sequencial sob incerteza.

4.2.1 Hipóteses determinísticas e lineares

Adota-se a linearidade dos custos em função dos comprimentos associados a cada evento operacional. Os três componentes, sucata, estoque e perda de venda, são proporcionais ao comprimento total gerado, estocado e não atendido no dia. Não se incluem custos fixos nem termos quadráticos, preservando uma função objetivo aditiva ao longo do tempo. O inventário é perfeitamente transferível entre dias, sem perdas de qualidade, e o processo de corte não inclui tempos de preparação explícitos além da restrição de trocas. Essa estrutura permite representar o sistema com estados discretos que agregam, por dia, estoque, demanda e recursos remanescentes.

4.2.2 Hipóteses estocásticas e temporais

A incerteza do sistema concentra-se na demanda, assumida estacionária ao longo do horizonte e diferenciada entre SKUs por grupos de frequência. Entre dias consecutivos, não se considera autocorrelação temporal, o que simplifica o aprendizado do agente sem comprometer o caráter intertemporal das decisões. Essa escolha segue recomendações clássicas de modelagem em Aprendizado por Reforço, nas quais o foco está em avaliar políticas sob variabilidade estatística controlada, e não em prever explicitamente o processo gerador de demanda (SUTTON; BARTO, 2018).

4.2.3 Notação essencial para a modelagem sequencial

Para cada dia t , o estado S_t reúne variáveis de estoque por SKU, demanda observada e recursos remanescentes. A ação a_t especifica uma decisão de produção consistente com o catálogo de padrões e com a capacidade. A recompensa instantânea r_t é o negativo do custo diário, de forma que maximizar o retorno acumulado equivale a minimizar o custo total esperado. Essa notação estabelece a ponte para a formulação markoviana subsequente.

4.2.4 Premissas de equivalência experimental

As comparações entre métodos utilizam exatamente o mesmo catálogo, os mesmos custos unitários e a mesma sequência de demandas, gerada por sementes fixas. Com isso, qualquer diferença de desempenho advém exclusivamente do mecanismo de decisão implementado pelo agente, e não de variações nas condições do ambiente (SU et al., 2023; PITOMBEIRA-NETO; MURTA, 2022).

4.3 FORMULAÇÃO COMO PROCESSO DE DECISÃO DE MARKOV

A formulação sequencial do problema de corte com estoques e demanda estocástica é convenientemente descrita como um Processo de Decisão de Markov, pois a evolução do sistema entre dias é completamente determinada pelo estado corrente, pela ação tomada e pela realização aleatória da demanda subsequente (PUTERMAN, 1994; SUTTON; BARTO, 2018). Essa escolha cria uma ponte formal entre a operação industrial e os métodos de Aprendizado por Reforço, permitindo que

políticas sejam otimizadas diretamente sobre trajetórias observadas, sem exigir um modelo analítico fechado para a dinâmica estocástica do ambiente (SUTTON; BARTO, 2018). Ao nivelar a linguagem do problema em termos de estados, ações, transições e recompensas, o MDP estabelece uma base única para comparar, de forma justa, políticas aprendidas com soluções determinísticas como o MILP (GILMORE; GOMORY, 1961).

Define-se o MDP como $\mathcal{M} = (S, A, P, R, \gamma)$, em que S é o conjunto de estados, A o conjunto de ações, $P(S_{t+1} | S_t, a_t)$ a lei de transição, $R(S_t, a_t)$ a recompensa instantânea e $\gamma \in (0, 1]$ o fator de desconto. O horizonte é finito com $T = 300$ decisões diárias e o desconto é próximo da unidade, refletindo o caráter intertemporal do custo no contexto produtivo (SUTTON; BARTO, 2018). O ambiente é totalmente observável, de modo que não há estados ocultos a inferir; a estocasticidade está concentrada unicamente na demanda do dia seguinte, enquanto as demais atualizações do sistema são determinísticas. Essa estrutura, por um lado, evita a necessidade de técnicas para observação parcial e, por outro, mantém a dificuldade combinatória intrínseca ao espaço de ações, que deriva do catálogo de padrões e das escolhas de intensidade de corte.

4.3.1 Propriedade markoviana e granularidade temporal

A propriedade markoviana afirma que, dados S_t e a_t , a distribuição de S_{t+1} independe do passado anterior a t . No problema de corte, isso é natural porque o histórico relevante é inteiramente transportado no próprio estado, via estoques, recursos do dia e marcador temporal. Não há efeitos de memória latente além do estoque carregado, e a rotina operacional do ambiente aplica as mesmas regras de atualização em todos os dias, o que torna a dinâmica estruturalmente estacionária. A variação diária resulta apenas do sorteio da demanda, cuja distribuição é mantida constante no episódio para garantir comparabilidade. Essa premissa limita a variabilidade do ambiente a flutuações aleatórias da demanda, não capturando mudanças estruturais ou choques exógenos típicos de contextos industriais reais, mas é adotada aqui como aproximação controlada para viabilizar a comparação consistente entre as abordagens avaliadas.

A granularidade das decisões é diária, mas o ambiente permite múltiplos lotes intra-dia por meio de trocas de padrão. Essa granularidade é encapsulada no modelo

markoviano pela ação composta que, em cada etapa, seleciona um padrão e sua intensidade. Com isso, o tratamento matemático permanece no passo diário, enquanto a estrutura de lotes e trocas afeta a factibilidade e o custo dentro do dia. Essa escolha preserva a fidelidade operacional sem inflar artificialmente a dimensão temporal do MDP (WÄSCHER; HAUSSNER; SCHUMANN, 2007; MARTELLO; VIGO, 2020).

4.3.2 Dinâmica de transição e fechamento do ciclo diário

A dinâmica de transição pode ser entendida como um ciclo em quatro movimentos encadeados. Primeiro, a demanda do dia é abatida no estoque inicial, produzindo a demanda remanescente a atender. Em seguida, a ação determina a produção por meio do padrão e da quantidade de chapas, respeitando recursos e restrições. Na sequência, o novo estoque é obtido pela diferença positiva entre disponibilidade e demanda, definindo o *carry-over* do sistema. Por fim, a demanda do dia seguinte é amostrada do processo estocástico, selando o sorteio que condicionará a decisão futura.

Matematicamente, a transição organiza esses movimentos em uma única aplicação de $P(\cdot \mid S_t, a_t)$. Não há ruído em nenhum passo além da última etapa, o que torna a contribuição estocástica isolada e bem controlada. Para o agente, essa estrutura é vantajosa: permite aprender empiricamente a resposta ótima às distribuições de demanda sem precisar identificá-las explicitamente, característica típica de abordagens modelo-livre bem-sucedidas em problemas de planejamento e controle (GILMORE; GOMORY, 1961; POLDI; ARENALES, 2010).

4.3.3 Objetivo de controle ótimo e comparação com MILP

O objetivo de controle é maximizar o retorno esperado da política π , $J(\pi) = \mathbb{E}_\pi \left[\sum_{t=1}^T \gamma^{t-1} r_t \right]$, em que $r_t = R(S_t, a_t)$ é o negativo do custo do dia. Como a recompensa é a negação do custo, a maximização de $J(\pi)$ coincide com a minimização do custo acumulado esperado. O MILP é resolvido sobre o mesmo catálogo de padrões de corte disponível ao agente de Aprendizado por Reforço. Esse

catálogo contempla todas as combinações geometricamente viáveis de padrões de corte consideradas no estudo, sendo fixado ao longo do horizonte. Assim, a restrição ao catálogo não implica limitação do espaço de soluções, mas apenas a imposição de condições operacionais idênticas entre as abordagens comparadas.

Sob horizontes longos e custos assimétricos, o agente de RL pode explorar políticas não-míopes que constroem amortecedores de estoque de forma seletiva, mitigando perdas futuras em períodos de alta demanda. Essa habilidade de internalizar efeitos intertemporais é justamente o benefício esperado de uma formulação markoviana com desconto próximo de um e recompensas alinhadas ao custo econômico (PITOMBEIRA-NETO; MURTA, 2022; SU et al., 2023).

4.4 ESPAÇO DE ESTADOS

O estado do dia t , denotado por S_t , contém as variáveis suficientes para prever a distribuição de S_{t+1} dada a ação. A observação inclui o estoque por SKU, a demanda pendente do dia, o número de chapas restantes, o número de blocos disponíveis para corte e a variável dia normalizado, que representa a fração do horizonte de 300 dias já transcorrida, expressa no intervalo $[0,1]$. A normalização da variável temporal para o intervalo $[0,1]$ corresponde a uma transformação linear do índice discreto do dia ao longo do horizonte considerado, preservando toda a informação temporal relevante. Assim, o espaço de estados normalizado permanece equivalente ao original, diferindo apenas pela escala adotada, o que contribui para maior estabilidade numérica no aprendizado do agente. Essa estrutura assegura suficiência informacional sem redundâncias, permitindo ao agente compreender a relação entre decisões, recursos e custos sem inflar desnecessariamente a dimensão do estado.

A normalização das variáveis não ocorre dentro do ambiente, mas é aplicada externamente durante o treinamento por um procedimento de padronização que ajusta observações e recompensas. Dessa forma, as entradas mantêm escalas compatíveis e favorecem a estabilidade numérica na estimação de valores. O vetor de estado resultante possui dimensão fixa e magnitude controlada, adequada às redes de decisão de baixa profundidade utilizadas pelo agente de aprendizado por reforço.

A suficiência do estado decorre de três propriedades fundamentais: (i) o estoque carrega a memória econômica das decisões anteriores; (ii) os recursos remanescentes (chapas e blocos) representam as restrições que limitam as ações; e (iii) o progresso temporal, expresso pelo dia normalizado, permite que o agente ajuste suas escolhas conforme a proximidade do fim do horizonte. Essa representação mantém a propriedade *markoviana* e oferece uma base estável para o aprendizado de políticas em um ambiente de decisão sequencial e sujeito à incerteza (SUTTON; BARTO, 2018).

4.5 ESPAÇO DE AÇÕES

A ação por bloco intra-dia é uma decisão composta que seleciona um padrão de corte do catálogo e a quantidade inteira de chapas a processar sob esse padrão. Escrevendo $a_t = (\text{idx}, q)$, a componente de índice referencia um vetor de contagens viável do catálogo, enquanto q regula a intensidade do lote antes de possível troca. Essa codificação preserva a semântica operacional do corte por lotes e mantém a factibilidade geométrica embutida, pois a produção herdar a composição do padrão escolhido.

A cardinalidade do espaço de ações é a principal fonte de complexidade combinatória. Mesmo com catálogos moderados, a combinação de padrões e intensidades cria um leque amplo de decisões possíveis. Em vez de enumerar exaustivamente, a política do agente PPO aprende distribuições sobre ações que, no estado corrente, concentram probabilidade nos padrões e intensidades mais promissoras. Essa estratégia é consistente com a filosofia de métodos de política proximal, que se adaptam bem a espaços discretos grandes mediante amostragem e atualização recortada (SCHULMAN et al., 2017). Na prática, isso é realizado por meio da atualização iterativa dos parâmetros da política estocástica, que aumenta a probabilidade de seleção de ações associadas a retornos mais elevados observados durante o treinamento, ao mesmo tempo em que reduz a probabilidade de ações menos eficientes, conforme o mecanismo de otimização do PPO.

A viabilidade geométrica é garantida a priori pelo catálogo; a capacidade residual de chapas e o orçamento de trocas são verificados no momento da decisão. A viabilidade geométrica dos padrões é garantida previamente pelo catálogo, enquanto as restrições operacionais, como capacidade residual de chapas e

orçamento de trocas, são verificadas no momento da decisão. Essa separação simplifica a definição do espaço de ações e evita que o agente selecione padrões geometricamente inválidos ou operacionalmente inaplicáveis. Uma vez escolhido o par (idx, q) , a produção efetiva é $q \cdot a_{idx}$, o que consolida o efeito do lote em uma única atualização do estado.

O efeito de lotes cria um trade-off intertemporal: lotes longos com um padrão subótimo podem inflar estoque indesejado, enquanto lotes curtos com trocas frequentes consomem rapidamente o orçamento de setups. A ação composta internaliza esse compromisso numa única escolha, e a política aprende a dosar a intensidade conforme o estado e o tempo restante, sem a necessidade de heurísticas externas.

4.6 FUNÇÃO DE RECOMPENSA E CUSTOS

A avaliação do agente é construída diretamente a partir do custo econômico diário do sistema. Ao longo do dia, as decisões são tomadas em blocos e apenas acumulam produção e sobras de corte; não há retorno parcial a cada bloco. O custo do dia é apurado somente ao seu término, quando se consolidam o que foi atendido, o que faltou e o que permaneceu em estoque. Nesse momento, o sinal que orienta o aprendizado corresponde ao negativo do custo diário total, reescalonado por um fator constante para estabilizar numericamente o treinamento. Nos passos intermediários dentro do dia, esse sinal é nulo. O reescalonamento consiste em dividir o custo diário total por um fator constante, definido empiricamente, com o objetivo de manter a magnitude do sinal de recompensa dentro de uma faixa numericamente estável durante o treinamento. No ambiente implementado, esse fator foi fixado em 3000.

O custo diário resulta da soma de três componentes. O primeiro é o custo de estocagem, obtido ao converter o estoque de saída do dia para milímetros equivalentes e multiplicá-lo por um coeficiente unitário. O segundo é o custo de sucata, que corresponde à sobra geométrica gerada pelos padrões aplicados no dia. O terceiro é o custo de falta, calculado a partir da demanda não atendida no próprio dia, também convertida para milímetros e ponderada por um coeficiente substancialmente superior aos demais, refletindo sua prioridade na hierarquia de penalidades. Na configuração utilizada, os coeficientes por milímetro são iguais a 3 para estoque, 35 para sucata e 700 para falta, e o reescalonamento do sinal no fechamento do dia

utiliza um fator igual a 3000. Assim, o custo total é a soma linear dos componentes de estoque, sucata e falta, e o sinal emitido ao final do dia é a sua negação dividida por esse fator de reescalonamento.

Do ponto de vista do procedimento, esse sinal só é gerado quando o dia termina por esgotamento dos blocos disponíveis ou da capacidade diária de chapas. Durante o treinamento, aplica-se normalização automática das observações e dos sinais para reduzir a variabilidade e estabilizar a aprendizagem; na fase de avaliação, essa normalização do sinal é desativada, e os custos e métricas são apresentados diretamente em unidades reais, preservando a interpretação econômica. Essa construção garante alinhamento estrito entre o que é otimizado pelo agente e o que é efetivamente medido nos relatórios, respeitando a hierarquia operacional que prioriza evitar falta, reduzir sucata e manter estoques sob controle.

A normalização dos sinais e variáveis observadas é empregada com o propósito de manter todas as magnitudes dentro de uma mesma ordem de grandeza, prevenindo que componentes de maior escala dominem o processo de aprendizado e provoquem instabilidades numéricas. Tal procedimento atua reduzindo a variabilidade do sinal de reforço responsável pela atualização da política, o que, por consequência, estabiliza as iterações de treinamento e acelera a convergência para um comportamento estacionário e consistente. Essa prática é especialmente relevante em ambientes que apresentam recompensas e observações com escalas heterogêneas, onde a discrepância entre grandezas pode comprometer o desempenho do agente. Diversos estudos destacam que a normalização adequada dos dados é fundamental para aprimorar a eficiência amostral e garantir estabilidade nos algoritmos de aprendizado por reforço, especialmente em aplicações de larga escala e em domínios contínuos (SUTTON; BARTO, 2018). A ocorrência efetiva do aprendizado é verificada empiricamente por meio da convergência das métricas de desempenho ao longo do treinamento, da estabilização da política aprendida e da melhoria consistente dos custos médios obtidos em relação a políticas de referência, conforme discutido na seção de resultados.

4.7 GERAÇÃO DE DEMANDA E ESTOCASTICIDADE

A demanda diária por produto é gerada por uma distribuição de contagem sobre-dispersa (Binomial Negativa), apropriada para contextos em que a variância excede a média e ocorrem picos e vales (PITOMBEIRA-NETO; PRATA, 2019). Para induzir heterogeneidade estrutural entre itens, cada SKU é associado, no início do episódio, a três grupos de frequência, raro, ocasional e frequente, com probabilidades 25%/50%/25% e médias típicas de 0,2; 0,6; 1,2 unidade/dia, respectivamente (parâmetros consolidados em 4.9.4). A sobre-dispersão é controlada por um parâmetro de dispersão fixo, de modo que a variabilidade reflita incertezas operacionais plausíveis. Para capturar variações idiossincráticas sem romper o perfil de cada grupo, aplica-se um ruído multiplicativo fraco centrado em 1. Concluída a amostragem, as contagens são convertidas para milímetros pela multiplicação pela largura do SKU, o que permite comparar de forma homogênea os componentes de custo (retalho, estoque e falta) e manter coerência com a capacidade nominal da linha descrita no capítulo 3.

Para garantir verossimilhança operacional e evitar dias com demandas vazias ou muito elevadas, o total diário em milímetros é ajustado em torno de uma meta de utilização de 72,5% da capacidade nominal, admitindo variação de 5%. Se o total excede o teto da faixa, procede-se a reescalonamento proporcional das contagens, com realocação determinística do resíduo priorizando larguras maiores, a fim de preservar as proporções relativas entre SKUs. Se o total fica abaixo do piso, realiza-se preenchimento incremental controlado até atingir o patamar mínimo, sem ultrapassar o teto. Assim, a série diária permanece compatível com o teto operacional e comparável entre períodos e métodos.

A reprodutibilidade é assegurada por duas sementes distintas: uma para a associação SKUs-grupos e outra para as amostragens diárias. Essa separação permite reconstruir exatamente as mesmas sequências ao comparar MILP e RL, garantindo que diferenças de desempenho decorram das decisões e não de cenários estocásticos distintos. Conceitualmente, a escolha da Binomial Negativa equivale a modelar uma taxa média aleatória em um processo de chegadas simples, representando heterogeneidades não observadas. Em linha com as hipóteses deste estudo, assume-se estacionariedade no horizonte de 300 dias; assim, a dificuldade intertemporal decorre do acoplamento entre demanda, estoque e restrições

operacionais, e não de sazonalidade explícita, o que é adequado para isolar a capacidade das políticas em lidar com variabilidade e decisões sequenciais.

4.8 POLÍTICA DE APRENDIZADO E ESTRUTURA COMPUTACIONAL

O agente PPO parametriza uma política estocástica $\pi_\theta(a | s)$ e uma função de valor $V_\phi(s)$ por redes de baixa profundidade e otimiza um objetivo com recorte de probabilidade relativa. Dadas vantagens estimadas $\hat{A}(s, a)$ e a razão $r_\theta(s, a) = \pi_\theta(a | s) / \pi_{\theta_{\text{old}}}(a | s)$, o objetivo central é:

$$L^{\text{clip}}(\theta) = \mathbb{E} \left[\min(r_\theta(s, a) \hat{A}(s, a), \text{clip}(r_\theta(s, a), 1 - \epsilon, 1 + \epsilon) \hat{A}(s, a)) \right], \quad (13)$$

acrescido de termos auxiliares para perda de valor e bônus de entropia. A estimação da vantagem utiliza o método de Vantagem Generalizada, com desconto γ próximo de um e parâmetro de decaimento que suaviza a variância sem introduzir viés significativo (SCHULMAN et al., 2017).

A coleta de experiências é feita em paralelo por múltiplas instâncias do ambiente, ampliando a diversidade de estados por atualização. Durante o treinamento, aplica-se normalização automática das observações e do sinal para estabilizar gradientes; na avaliação, os custos são apurados em unidades reais, sem normalização. As atualizações ocorrem em janelas fixas de passos, e o comparativo com o modelo determinístico usa o mesmo catálogo, os mesmos custos e a mesma sequência de demanda reconstruída, isolando o efeito do mecanismo de decisão.

O objetivo limita mudanças excessivas entre atualizações e previne colapsos da política, enquanto o termo de entropia preserva exploração suficiente em espaços de ação extensos. A escolha de tamanhos de lote e de passos por atualização busca o equilíbrio clássico entre viés e variância na estimação do gradiente, conforme diretrizes consolidadas na literatura de aprendizado por reforço (SCHULMAN et al., 2017).

4.9 PARÂMETROS NUMÉRICOS ADOTADOS NO CÓDIGO

Esta seção consolida, em um só lugar, os valores efetivamente utilizados na implementação, de forma a permitir reprodutibilidade dos resultados e leitura cruzada com as análises.

4.9.1 Custos e hierarquia de penalidades

Faltas, retalho (sucata geométrica) e estoque seguem a hierarquia definida no texto: 700/mm, 35/mm e 3/mm, respectivamente. O sinal de aprendizado no fechamento do dia é o negativo do custo diário reescalonado por 3000 (normalização de sinais apenas no treino). Há teto de 40 unidades por SKU; excesso sofre descarte.

4.9.2 Geometria da chapa e catálogos de padrões

Largura por passada = 1.200 mm. Catálogo E5: 21 padrões. Catálogo E20: 860 padrões com limpeza off-line que remove retalho > 100 mm (a filtragem é prévia à execução do código).

4.9.3 Capacidade operacional, blocos intra-dia e espaço de ação

A capacidade diária da linha é de 50 chapas, totalizando 60.000 mm processáveis por dia. O ambiente opera com um orçamento máximo de 8 blocos de decisão, cada um correspondendo a um lote de corte. Cada ação consome um bloco, ainda que nenhuma chapa seja efetivamente processada. O dia é encerrado quando os blocos se esgotam, quando não restam chapas disponíveis ou quando o próprio agente opta por finalizar antecipadamente o ciclo diário. O espaço de ações é exclusivamente definido pela seleção de um padrão de corte dentre aqueles existentes no catálogo viável (21 padrões no ambiente E5 e 860 no ambiente E20).

4.9.4 Geração de demanda e teto operacional diário

Três grupos de frequência: 25% / 50% / 25% com médias 0,2; 0,6; 1,2 unidades/dia; dispersão $k = 1,2$; ruído multiplicativo com desvio relativo 0,15 (apenas em contagens positivas). Utilização-alvo: $72,5\% \pm 5\%$ da capacidade, isto é, alvo 43.500 mm e faixa 41.325–45.675 mm. Horizonte: 300 dias. Sementes: 2 (grupos e demandas).

4.9.5 Hiperparâmetros do agente de política proximal

O agente utiliza fator de desconto = 0,995, taxa de aprendizado = 0,00015, janelas de 4096 passos por atualização, lote de 2048 amostras por atualização e 10 épocas de otimização por atualização. Os limites de recorte da atualização da política e o bônus de entropia são, respectivamente, 0,15 e 0,006. O número de passos totais de treinamento por execução é de 200 000. A coleta paralela de experiências ocorre em múltiplas instâncias independentes do ambiente, com número de ambientes configurável; no caso médio, utiliza-se valor típico de 8 instâncias paralelas durante o treinamento. Observações e sinal de aprendizado são padronizados automaticamente no treinamento para estabilizar gradientes; na avaliação, a padronização do sinal é desativada e os custos são apurados em unidades reais.

4.10 AMBIENTE DE APRENDIZADO

Para facilitar a consulta aos parâmetros efetivamente utilizados na implementação, consolida-se neste ponto um quadro síntese com os hiperparâmetros de treinamento do agente PPO e as principais configurações de normalização e reprodutibilidade adotadas no código. O Quadro 1 reúne esses valores em formato objetivo, servindo como referência direta para a interpretação dos resultados apresentados no capítulo 5 e para a replicação dos experimentos.

Quadro 1 - Parâmetros de implementação (código/configuração)

Parâmetro	Valor
Algoritmo	PPO (SB3)
Policy	MlpPolicy
net_arch (pi)	[64, 64] (default SB3)
net_arch (vf)	[64, 64] (default SB3)
activation_fn	tanh (default SB3)
γ (gamma)	0,995
λ (gae_lambda)	0,95 (default SB3)
α (learning_rate)	$1,5e-4$
n_steps	4096
batch_size	2048
n_epochs	10
clip_range	0,15
ent_coef	0,006
vf_coef	0,5 (default SB3)
max_grad_norm	0,5 (default SB3)
target_kl	None (default SB3)
total_timesteps	200000
n_envs	CLI --n-envs (senão 8; senão cpu_total-1)
seed_global	CLI --seed (senão 123)
seed_groups	777
seed_demands	4242
VecNormalize (treino)	norm_obs=True; norm_reward=True
VecNormalize (clipping)	clip_obs=10; clip_reward=10
eval_vecnorm.training	False
eval_vecnorm.norm_reward	False
reward_scale	3000

Fonte: elaborado pelo autor

5 RESULTADOS

Este capítulo apresenta os resultados obtidos a partir das simulações com os dois métodos propostos para o problema de corte de bobinas: Programação Linear Inteira (PLI) e Aprendizado por Reforço Proximal Policy Optimization (PPO). As análises são realizadas em dois cenários distintos: o primeiro com 5 SKUs (E5), de menor complexidade, e o segundo com 20 SKUs (E20), de maior complexidade. Os dados utilizados nesta análise correspondem à média de quatro simulações independentes realizadas para cada método nos dois ambientes. Os resultados são organizados de forma a destacar o comportamento individual de cada abordagem e, em seguida, realizar uma comparação direta entre elas, utilizando métricas como custo acumulado, retalho, perda de venda e inventário médio.

5.1 RESULTADOS DO MODELO PLI

O Quadro 2 apresenta os valores médios diários obtidos pelas simulações do modelo de Programação Linear Inteira (PLI) nos ambientes com 5 e 20 SKUs:

Quadro 2 – Resultados PLI

Indicador (mm)	5 SKUs	20 SKUs
Custo médio diário	313.168,63	1.933.139,97
Retalho médio diário	7.251,00	3.748,84
Estoque médio diário	19.794,54	94.969,98
Perda de vendas média diária	0,00	2.159,59

Fonte: elaborado pelo autor

No cenário com 5 SKUs, o modelo de Programação Linear Inteira apresentou desempenho consistente, com crescimento do custo acumulado de forma controlada e sem ocorrência de perdas de venda, conforme as Figuras 3 e 9, respectivamente. O inventário médio foi relativamente estável, apresentando baixa dispersão ao longo do horizonte simulado. O retalho diário foi moderado, permanecendo dentro de limites aceitáveis ao longo do tempo.

Ao comparar os dois cenários, observa-se que a variação do estoque médio entre o ambiente de 5 SKUs e o de 20 SKUs foi superior a 380% (Figura 6), refletindo

a necessidade de maior volume de produto para cobertura de uma demanda mais complexa. Da mesma forma, o desvio padrão do inventário aumentou em aproximadamente 460%, indicando uma maior instabilidade no controle de estoque no cenário mais complexo.

No que se refere à perda de venda, o modelo não apresentou falhas no atendimento da demanda no cenário de 5 SKUs. Entretanto, no ambiente com 20 SKUs, observou-se uma deterioração expressiva nesse aspecto, com crescimento relevante da quantidade perdida, conforme apresentado na Figura 9. Este comportamento contribuiu de forma decisiva para o aumento do custo acumulado nesse cenário. A perda de venda, por sua natureza, possui um peso expressivo na função objetivo, pois além de representar uma ineficiência operacional direta, também é um parâmetro fundamental no treinamento do modelo PPO. Durante o processo de aprendizagem por reforço, essa métrica atua como penalização que orienta o agente a desenvolver políticas de antecipação de demanda. O modelo PLI, por sua vez, não possui esse mecanismo de adaptação, o que limita sua capacidade de evitar rupturas em ambientes com alta variabilidade.

No cenário com 5 SKUs, o modelo PLI apresentou retalho médio diário de 7,3 mm. Já no ambiente com 20 SKUs, essa média caiu para 3,7 mm, o que representa uma redução de aproximadamente 48,3%, observada na Figura 8. Essa diferença pode indicar que, diante da maior diversidade de itens e padrões viáveis, o modelo passou a priorizar combinações de corte com menor sobra de material. No entanto, tal economia não foi suficiente para compensar o crescimento expressivo das perdas de venda no cenário mais complexo, resultando em um custo acumulado total significativamente mais elevado.

Esses resultados demonstram que, embora o modelo PLI seja eficaz em contextos de baixa complexidade, sua aplicação direta em cenários mais amplos resulta em limitações relevantes, sobretudo quanto à sua capacidade de prever e ajustar-se dinamicamente às variações da demanda. As evidências numéricas que sustentam essa análise serão aprofundadas na Seção 5.3, com o suporte de representações visuais nas Figuras 3 a 9, que comparam diretamente os resultados da PLI com os do PPO para ambas as configurações de ambiente.

5.2 RESULTADOS DO MODELO DE APRENDIZADO POR REFORÇO

O Quadro 3 apresenta os valores médios diários obtidos pelo agente de Aprendizado por Reforço (PPO) nos ambientes com 5 e 20 SKUs.

Quadro 3 – Resultados RL

Indicador (mm)	5 SKUs	20 SKUs
Custo médio diário	310.836,90	505.762,39
Retalho médio diário	7.475,69	5.453,42
Estoque médio diário	16.047,84	94.765,38
Perda de vendas média diária	1,49	32,42

Fonte: elaborado pelo autor

No cenário com 5 SKUs, o modelo PPO apresentou desempenho equivalente ao da PLI em termos de custo acumulado (Figura 3). Entretanto, sua política de operação resultou em níveis de estoque aproximadamente 20% inferiores (Figura 6), evidenciando uma estratégia mais restritiva de controle de inventário. Essa abordagem é condizente com a natureza adaptativa do algoritmo, que busca equilibrar disponibilidade e minimização de excesso. O retalho médio diário foi levemente superior ao observado na PLI (Figura 8), o que sugere maior variação nos padrões de corte adotados. A perda de venda, ainda que não nula, foi residual, mantendo-se próxima de zero na maior parte do horizonte de simulação, conforme Figura 9. A ocorrência esporádica de perdas pontuais não comprometeu o desempenho geral, demonstrando robustez no atendimento da demanda mesmo com políticas de estoque mais conservadoras. A variabilidade observada nos níveis de estoque e custo diário foi mais acentuada do que na PLI, reflexo do caráter exploratório do PPO.


No cenário de 20 SKUs, a diferença de desempenho entre os métodos torna-se mais evidente. O PPO apresenta custo acumulado total consideravelmente inferior ao da PLI, evidenciado na Figura 5, mesmo operando com níveis médios de estoque semelhantes (Figura 7). Essa diferença se deve principalmente à capacidade do agente de evitar perdas de venda de forma mais eficaz.

Apesar da elevação no retalho médio diário em relação ao cenário de 5 SKUs, o modelo conseguiu manter a perda de venda em níveis baixos, com mediana nula e média controlada. Esse comportamento reforça o papel da penalização da perda de

venda no processo de aprendizado: o agente é induzido a formar estoques preditivos e adaptar-se às exigências de um ambiente mais dinâmico.

A recompensa média por episódio ao longo do treinamento no cenário de 20 SKUs evidencia a convergência do modelo, conforme ilustrado na Figura 1. Essa métrica é indicativa da estabilização da política aprendida e da internalização das penalizações associadas à perda de venda, retalho e inventário elevado.


Figura 1 – Recompensa por episódio



Fonte: elaborado pelo autor

Complementarmente, a Figura 2 apresenta a evolução do custo acumulado final ao longo dos 420 agentes PPO treinados com seed 987 no ambiente de 20 SKUs. A trajetória descendente revela uma tendência clara de redução de custo à medida que os episódios de treinamento avançam, com estabilização progressiva em torno de valores mínimos a partir do centésimo PPO. Esse comportamento evidencia o aprendizado do agente e a convergência das políticas para soluções mais eficientes e robustas. Ainda que haja flutuações iniciais, especialmente nas primeiras 30 execuções, observa-se uma redução acentuada e consistente do custo acumulado até a estabilização da performance.

Figura 2 – Custo acumulado por PPO




Fonte: elaborado pelo autor

Os efeitos dessas decisões sobre as variáveis de desempenho serão aprofundados na Seção 5.3, com apoio das Figuras 3 a 9, que contextualizam o PPO em relação ao modelo PLI em termos de custo, estoque, retalho e perda de venda.

5.3 COMPARAÇÃO ENTRE PLI E RL

A Figura 3 compara a evolução média do custo acumulado diário entre os métodos PLI e PPO nos dois ambientes. Verifica-se que, no cenário com 5 SKUs, ambos os métodos exibem trajetórias semelhantes. Entretanto, no ambiente de 20 SKUs, o PPO apresenta crescimento mais contido e estável do custo, sugerindo maior capacidade de contenção de penalidades associadas ao desempenho operacional.


Figura 3 – Custo acumulado médio



Fonte: elaborado pelo autor

Na Figura 4, a análise da dispersão dos custos diários consolida essa percepção. O PPO mantém menor variabilidade no cenário de 20 SKUs, enquanto o PLI revela maior amplitude de flutuação e picos acentuados de custo.


Figura 4 – Distribuição dos custos



Fonte: elaborado pelo autor

O custo total acumulado por cenário e método é apresentado na Figura 5. A disparidade entre os métodos se acentua no ambiente de 20 SKUs, em que o PPO alcança menor valor total em relação à PLI. No cenário de 5 SKUs, a diferença entre os modelos é pouco significativa.


Figura 5 – Custo total acumulado



Fonte: elaborado pelo autor

A Figura 6 mostra o comportamento agregado do inventário médio por método e ambiente. O PPO mantém menor nível médio em ambos os cenários, evidenciando sua tendência a operar com estoques mais enxutos. Essa decisão é compatível com seu aprendizado penalizado por excesso de inventário.


Figura 6 – Estoque médio



Fonte: elaborado pelo autor

Esse padrão também se confirma na análise temporal da Figura 7, em que se observa uma evolução mais contida e ajustada do estoque médio diário ao longo do tempo no PPO, especialmente no ambiente de maior complexidade.


Figura 7 – Evolução do estoque diário



Fonte: elaborado pelo autor

No que diz respeito ao retalho, a Figura 8 indica que o PPO apresenta menores volumes acumulados no cenário de 20 SKUs, contrastando com o desempenho da PLI, que enfrenta maior dificuldade em manter cortes ajustados. Já no ambiente de 5 SKUs, as diferenças são menos pronunciadas.


Figura 8 – Retalho total



Fonte: elaborado pelo autor

Por fim, a Figura 9 sintetiza a comparação da perda de venda total acumulada. O PPO demonstra desempenho superior em ambos os ambientes, especialmente no de 20 SKUs, onde a PLI sofre penalizações significativas. Este resultado reforça o impacto da estrutura de treinamento por reforço na formação de estoques preditivos mais eficientes.

Figura 9 – Perda de venda



Fonte: elaborado pelo autor

5.4 DISCUSSÃO DOS RESULTADOS

A análise dos resultados obtidos nas seções anteriores permite refletir com profundidade sobre o desempenho comparativo entre o modelo de Programação Linear Inteira (PLI) e o agente de Aprendizado por Reforço (PPO), considerando os diferentes graus de complexidade operacional representados pelos ambientes de 5 e 20 SKUs. Observa-se que, embora ambos os métodos apresentem desempenho satisfatório em cenários de baixa complexidade, o PPO demonstra superioridade significativa em contextos de maior exigência decisória.

No cenário com 5 SKUs, os dois métodos apresentaram desempenho próximo, com custo médio diário praticamente equivalente: R\$ 313.168,63 para o PLI

e R\$ 310.836,90 para o PPO. Em termos de perda de venda, ambos se mantiveram próximos a zero, com o PPO apresentando uma média de apenas 1,49 mm por dia, ao custo de um leve incremento no retalho médio diário (7.475,69 mm contra 7.251,00 mm do PLI). O estoque médio diário foi de 19.794,54 mm para o PLI e 16.047,84 mm para o PPO, evidenciando uma política mais conservadora do agente, que ainda assim manteve desempenho comparável. Essa convergência de desempenho sugere que, em sistemas com baixa variabilidade e menor número de decisões simultâneas, a estrutura determinística da PLI é suficiente para produzir soluções competitivas.

Contudo, no ambiente de 20 SKUs, o PPO se destaca de maneira mais clara. O custo médio diário foi de R\$ 505.762,39 contra R\$ 1.933.139,97 da PLI, uma redução de aproximadamente 73,8%. A perda de vendas média diária caiu de 2.159,59 mm (PLI) para 32,42 mm (PPO), correspondendo a uma redução de 98,5%. O estoque médio diário foi semelhante entre os métodos (94.969,98 mm no PLI contra 94.765,38 mm no PPO), enquanto o retalho médio diário foi maior no PPO (5.453,42 mm contra 3.748,84 mm). Esses dados revelam a capacidade do agente de adaptar-se a um ambiente mais dinâmico e incerto, antecipando demandas e minimizando penalizações críticas.

A diferença de desempenho evidencia que o PLI enfrenta dificuldade em lidar com a explosão combinatória do espaço de decisões no cenário de 20 SKUs, resultando em maior volume de perda de venda, principal responsável pela elevação do custo total. Essa limitação estrutural está ligada à ausência de mecanismos de aprendizado e adaptação no modelo clássico, que opera de maneira míope e estática, otimizando decisões localmente a cada dia.

Além dos ganhos operacionais, o PPO demonstrou maior robustez estatística ao longo de múltiplas simulações, conforme verificado na menor variabilidade dos custos acumulados diários (desvio-padrão de 563 no PPO contra 1.254 na PLI). A estabilidade da curva de recompensa média por episódio, apresentada na Figura 1, reforça a convergência do processo de aprendizagem. O comportamento emergente do PPO, como a formação de estoques preditivos, é resultado direto da estrutura sequencial do algoritmo e da penalização severa associada à perda de venda durante o treinamento.

Essa métrica, a perda de venda, atua como principal indutor de comportamento, levando o agente a desenvolver políticas antecipatórias e de

segurança. Ao contrário do PLI, que não incorpora memória intertemporal, o PPO aprende a equilibrar custos ao longo do horizonte de simulação, assumindo estoques maiores em momentos estratégicos para evitar rupturas futuras.

Por fim, cabe mencionar que, embora o PPO apresente variabilidade natural decorrente da política exploratória, essa flutuação é compensada por ganhos consistentes nos indicadores agregados. Além disso, embora não tenha sido métrica de avaliação na presente pesquisa, o tempo computacional necessário para resolver o modelo PLI foi, em média, aproximadamente 80 vezes superior ao necessário para treinar os agentes PPO no ambiente de 20 SKUs. Essa diferença reforça as limitações práticas do modelo clássico em aplicações com necessidade de replanejamento frequente e alta dimensionalidade.

Portanto, a análise consolidada dos resultados permite afirmar que, em ambientes de maior complexidade, o Aprendizado por Reforço representa uma alternativa superior em termos de desempenho, adaptabilidade e viabilidade computacional.

6 CONCLUSÃO

A pesquisa teve como objetivo central a análise e comparação de duas abordagens para o Problema de Corte de Bobinas: uma baseada em Programação Linear Inteira (PLI) e outra fundamentada em Aprendizado por Reforço, com foco no algoritmo Proximal Policy Optimization (PPO). Os resultados obtidos permitiram constatar que o agente PPO, uma vez treinado, é capaz de superar a abordagem PLI diária em cenários de maior complexidade, mantendo desempenho robusto, adaptabilidade às variações de demanda e maior eficiência computacional. A seguir, discute-se o cumprimento dos objetivos específicos, os principais resultados comparativos entre os métodos e as contribuições técnicas alcançadas.

O primeiro objetivo específico consistiu na construção de ambientes de simulação com diferentes níveis de complexidade, sendo definidos dois contextos distintos: um ambiente com 5 SKUs e outro com 20 SKUs. Essa definição permitiu representar dois regimes operacionais contrastantes – um com baixa complexidade e outro com elevada dimensionalidade decisória. Ambos os ambientes foram configurados com horizonte de 300 dias, capacidade de 50 chapas por dia, limite de 8 blocos por dia, e custos por milímetro: 3 para estoque, 35 para retalho e 700 para falta de produto. A demanda foi gerada por distribuição binomial negativa com ruído, e a recompensa diária foi escalada por um fator de 3000. As larguras dos SKUs foram mantidas constantes conforme catálogo, garantindo consistência estrutural entre os episódios.

O segundo objetivo específico tratou da implementação dos dois métodos de solução. O modelo de Programação Linear Inteira foi desenvolvido como um sistema estático de alocação de corte por otimização pontual, resolvendo o problema dia a dia de forma míope, sem memória de períodos anteriores ou horizonte móvel. Essa característica faz da PLI uma referência útil como base determinística, porém limitada em contextos com interdependência temporal. Já o agente de Aprendizado por Reforço foi construído e treinado sob a lógica de um processo sequencial, estruturado como um Processo de Decisão de Markov, com vetor de estado composto por demanda e estoque do dia, ação definida como o padrão de corte e quantidade de blocos, e função de recompensa composta pela penalização total (retalho, estoque e perda de venda). As políticas foram avaliadas em modo determinístico, reforçando a reprodutibilidade dos resultados.

O terceiro objetivo consistiu na análise comparativa entre os métodos, considerando métricas de desempenho como custo acumulado, perda de venda, estoque médio e retalho. Os dados foram organizados em relatórios, calculados com base na média de quatro execuções independentes por cenário. No ambiente de 5 SKUs, os dois métodos apresentaram desempenho próximo, com custo total acumulado aproximado. Já no cenário de 20 SKUs, as diferenças tornaram-se evidentes: o PPO reduziu o custo acumulado em 17,3% e a perda de venda total em 91,4% em relação à PLI, conforme ilustrado nas Figuras 3 e 5. Além disso, o estoque médio do PPO foi 4,9% inferior, mesmo com penalidade significativa por perda, indicado na Figura 6.

A Figura 4 indica que o PPO apresentou menor variabilidade na série temporal de custo acumulado no ambiente de 20 SKUs. O desvio-padrão diário do PPO foi de aproximadamente 563, enquanto o da PLI atingiu 1.254, evidenciando comportamento mais estável. A formação de estoques preditivos no PPO emerge como resultado do aprendizado sequencial orientado por penalizações futuras, permitindo antecipar rupturas de estoque e suavizar as decisões de corte ao longo do tempo. Esse comportamento contribui diretamente para a redução da perda de venda (Figura 9) e para o controle do inventário sem necessidade de sobreposição excessiva.

Embora o PPO apresente maior retalho médio diário no ambiente de 5 SKUs, essa diferença não comprometeu o desempenho geral. Em contrapartida, no cenário com 20 SKUs, o PPO também superou a PLI no controle do retalho acumulado, como observado na Figura 8. A recompensa média por episódio, apresentada na Figura 1, demonstra a convergência estável da política ao longo do treinamento.

Os três objetivos do trabalho foram, assim, plenamente atingidos. A construção dos ambientes permitiu simular contextos realistas com diferentes níveis de complexidade; a implementação dos métodos ofereceu contraste entre abordagens estáticas e adaptativas; e a análise comparativa confirmou a superioridade do Aprendizado por Reforço em ambientes com maior dimensionalidade. O agente PPO demonstrou comportamento robusto, com capacidade de generalização entre diferentes simulações e adaptação às variações estocásticas de demanda. As políticas aprendidas apresentaram características compatíveis com a prática industrial: manutenção de estoques de segurança para SKUs de baixa frequência, corte ajustado em períodos de maior exigência e estabilização das decisões ao longo do tempo.

Do ponto de vista teórico, o estudo contribui ao demonstrar que o uso de Aprendizado por Reforço é aplicável a problemas logísticos clássicos, como o corte de bobinas, desde que a modelagem do ambiente e a definição das penalizações estejam adequadas (Sutton e Barto, 2018; Schulman et al., 2017). A representação do problema como um Processo de Decisão de Markov permitiu capturar dependências intertemporais e antecipar efeitos acumulativos que os métodos pontuais não conseguem prever. A estrutura sequencial e adaptativa do PPO revelou-se mais eficiente, especialmente em contextos com múltiplos produtos e alta variabilidade operacional.

Do ponto de vista prático, a principal contribuição do trabalho está em demonstrar que agentes treinados previamente podem ser utilizados em tempo de execução com eficiência e baixo custo computacional. O PPO apresentou decisões alinhadas com o objetivo de minimizar o custo total e adaptar-se às flutuações de demanda, configurando-se como uma alternativa promissora para cenários que exigem estratégias responsivas e coordenação dinâmica entre múltiplas decisões operacionais.

Em termos de limitações, reconhece-se que o ambiente de simulação adotado é ainda simplificado, com horizonte fixo, estrutura de custos estática e ausência de restrições operacionais adicionais. Futuras pesquisas podem explorar variações na janela de planejamento, sazonalidade nas demandas, múltiplos turnos de operação e integração com dados reais de produção. Também seria relevante investigar algoritmos alternativos ao PPO, bem como arquiteturas de rede mais profundas, capazes de capturar interações complexas entre os SKUs e entre decisões passadas e futuras. Como trabalho futuro, destaca-se a inclusão de um nível mínimo de estoque de segurança para ambos os agentes avaliados, com o objetivo de reduzir a ocorrência de perdas de venda ao longo do horizonte. Em particular, a adoção explícita de um estoque mínimo no modelo determinístico poderia mitigar a natureza excessivamente míope da formulação diária do PLI, aproximando seu comportamento de decisões mais conservadoras frente à incerteza da demanda. Adicionalmente, trabalhos futuros podem considerar a comparação do agente de RL com modelos de *benchmark* mais completos, tais como formulações determinísticas com planejamento multiperíodo, modelos estocásticos de dois estágios ou abordagens híbridas que combinem PLI com heurísticas de reotimização. A inclusão desses *benchmarks* permitiria uma avaliação mais abrangente do desempenho do RL, especialmente em

cenários com incerteza de demanda e decisões intertemporais mais ricas, tornando a comparação metodologicamente mais robusta.

Conclui-se, portanto, que o Aprendizado por Reforço com PPO se mostrou uma alternativa eficaz ao modelo clássico de PLI, especialmente em contextos de maior complexidade. A estrutura adaptativa, a eficiência computacional e a robustez estatística do PPO evidenciam o potencial dessa abordagem para problemas de decisão sequencial sob variabilidade e restrições combinatórias. O trabalho contribui, assim, tanto para o avanço acadêmico no uso de técnicas de Aprendizado por Reforço em Pesquisa Operacional quanto para a exploração de métodos mais adaptativos e eficientes em formulações complexas de planejamento.

REFERÊNCIAS

- ABRACIA. **Relatório setorial sobre demanda por blanks automotivos e chapas galvanizadas**. [S. l.]: [s. n.], 2024.
- ARENALES, M. et al. *Pesquisa operacional para cursos de engenharia*. 2. ed. São Paulo: Campus Elsevier, 2015.
- BELLMAN, R. **Dynamic Programming**. Princeton: Princeton University Press, 1957.
- BROCKMAN, G. et al. **OpenAI Gym**, 2016. Disponível em: <https://arxiv.org/abs/1606.01540>. Acesso em: 10 jul. 2025
- CHERRI, A. C. et al. **A column generation approach for one-dimensional cutting stock problems with usable leftovers**. *Computers & Operations Research*, v. 74, p. 142–154, 2016.
- CRU INTERNATIONAL. **Steel Sheet Products Market Outlook: Q3 2024**. London: CRU Group, 2024.
- DYCKHOFF, H. **A typology of cutting and packing problems**. *European Journal of Operational Research*, v. 44, n. 2, p. 145–159, 1990.
- DYCKHOFF, H.; FINKE, U. **Cutting and Packing in Production and Distribution: A Typology and Bibliography**. Berlin: Springer, 1992.
- FANG, Y. et al. **Solving one-dimensional cutting stock problems with deep reinforcement learning**. *Mathematics*, v. 11, n. 5, 1123, 2023.
- FIELD, A. **Discovering Statistics Using IBM SPSS Statistics**. 5. ed. London: SAGE Publications, 2018.
- GILMORE, P. C.; GOMORY, R. E. **A linear programming approach to the cutting-stock problem**. *Operations Research*, v. 9, n. 6, p. 849–859, 1961. DOI: 10.1287/opre.9.6.849.

GILMORE, P. C.; GOMORY, R. E. **A linear programming approach to the cutting-stock problem**—Part II. *Operations Research*, v. 11, n. 6, p. 863–888, 1963. DOI: 10.1287/opre.11.6.863.

HINXMAN, A. I. **The trim-loss and assortment problems**: a survey. *European Journal of Operational Research*, v. 5, n. 1, p. 8–18, 1980.

HUNTER, J. D. **Matplotlib**: A 2D graphics environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90–95, 2007.

IEA – INTERNATIONAL ENERGY AGENCY. **Iron and Steel** – Tracking Report 2023. Paris: IEA, 2023. Disponível em: <https://www.iea.org/>. Acesso em: 11 jul. 2025.

INSTITUTO AÇO BRASIL. **Anuário Estatístico do Aço 2024**. Rio de Janeiro: Instituto Aço Brasil, 2024. Disponível em: <https://acobrasil.org.br/>. Acesso em: 2 jul. 2025.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Pesquisa Industrial Mensal** – Produção Física Brasil. Rio de Janeiro: IBGE, 2024. Disponível em: <https://www.ibge.gov.br/>. Acesso em: 6 jul. 2025.

KAELBLING, L. P.; LITTMAN, M. L.; MOORE, A. W. **Reinforcement learning**: A survey. *Journal of Artificial Intelligence Research*, v. 4, p. 237–285, 1996. DOI: 10.1613/jair.301.

LAKATOS, E. M.; MARCONI, M. A. **Fundamentos de metodologia científica**. 9. ed. São Paulo: Atlas, 2021.

LAW, A. M.; KELTON, W. D. **Simulation Modeling and Analysis**. 5. ed. New York: McGraw-Hill, 2021.

LÜBBECKE, M. E.; DESROSIERS, J. **Selected topics in column generation**. *Operations Research*, v. 53, n. 6, p. 1007–1023, 2005.

MARTELLO, S.; TOTH, P. **Knapsack Problems: Algorithms and Computer Implementations**. Chichester: John Wiley & Sons, 1990.

MCKINNEY, W. **Data structures for statistical computing in Python**. In: VAN DER WALT, S.; MILLMAN, J. (org.). *Proceedings of the 9th Python in Science Conference*. Austin, 2010. p. 51–56.

MITCHELL, S.; ROHENKOHL, P.; REINELT, G. **Pulp**: a linear programming toolkit for Python. *INFORMS Tutorials in Operations Research*, p. 1–16, 2011.

MNIH, V. et al. **Human-level control through deep reinforcement learning**. *Nature*, v. 518, p. 529–533, 2015. DOI: 10.1038/nature14236.

MOHAMMED, A. et al. **A survey on reinforcement learning and its applications in operations research**. *European Journal of Operational Research*, v. 284, n. 3, p. 683–705, 2020.

PITOMBEIRA-NETO, A. R.; MURTA, C. A. S.; ZUFFO, M. K. **A reinforcement learning approach to the stochastic cutting stock problem**. *EURO Journal on Computational Optimization*, v. 10, p. 100072, 2022. DOI: 10.1016/j.ejco.2022.100072.

POWELL, W. B. **Approximate Dynamic Programming: Solving the Curses of Dimensionality**. 2. ed. Hoboken: John Wiley & Sons, 2011.

PUTERMAN, M. L. **Markov Decision Processes: Discrete Stochastic Dynamic Programming**. New York: John Wiley & Sons, 1994.

SAUNDERS, M.; LEWIS, P.; THORNHILL, A. **Research Methods for Business Students**. 8. ed. Harlow: Pearson, 2019.

SARGENT, R. G. **Verification and validation of simulation models**. *Journal of Simulation*, v. 7, n. 1, p. 12–24, 2013.

SCHULMAN, J. et al. **Proximal Policy Optimization Algorithms**. arXiv preprint, arXiv:1707.06347, 2017. Disponível em: <https://arxiv.org/abs/1707.06347>. Acesso em: 19 jul. 2025.

SILVA, E. L.; MENEZES, E. M. **Metodologia da pesquisa e elaboração de dissertação**. 4. ed. Florianópolis: UFSC, 2005.

SU, J.-Y.; CHEN, C.-Y.; CHENG, Y.-C.; CHANG, C.-K. **An Actor–Critic Algorithm for the Stochastic Cutting Stock Problem**. Processes, v. 11, n. 4, e1031, 2023. DOI: 10.3390/pr11041031.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning: An Introduction**. 2. ed. Cambridge: MIT Press, 2018.

TAHA, H. A. **Operations Research: An Introduction**. 10. ed. Harlow: Pearson, 2017.

VANCE, P. H. et al. **Solving binary cutting stock problems by column generation**. INFORMS Journal on Computing, v. 6, n. 2, p. 192–205, 1994.

VANDERPLAS, J. **Python Data Science Handbook: Essential Tools for Working with Data**. Sebastopol: O'Reilly Media, 2016.

VRABIE, D.; LEWIS, F. L.; WANG, K. **Adaptive Dynamic Programming for Control: Algorithms and Stability**. Boca Raton: CRC Press, 2013.

WÄSCHER, G.; GAU, T. **Heuristics for the integer one-dimensional cutting stock problem: A computational study**. OR Spektrum, v. 18, p. 131–144, 1996. DOI: 10.1007/BF01539780.

WÄSCHER, G.; HAUSSNER, H.; SCHUMANN, H. **An improved typology of cutting and packing problems**. European Journal of Operational Research, v. 183, n. 3, p. 1109–1130, 2007.

WILLIAMS, R. J. **Simple statistical gradient-following algorithms for connectionist reinforcement learning**. Machine Learning, v. 8, n. 3–4, p. 229–256, 1992. DOI: 10.1007/BF00992696.

WORLD STEEL ASSOCIATION. **World Steel in Figures 2024**. Brussels: World Steel Association, 2024. Disponível em: <https://worldsteel.org/>. Acesso em: 24 jul. 2025.

ZHANG, K.; YANG, Z.; BASAR, T. **Multi-Agent Reinforcement Learning**: A Selective Overview of Theories and Algorithms. Handbook of Reinforcement Learning and Control. Cham: Springer, 2021.